CN 43-1258/TP
ISSN 1007-130X

计算机工程与科学
Computer Engineering & Science

第 46 卷第 1 期 2024 年 1 月
Vol. 46, No. 1, Jan. 2024

文章编号:1007-130X(2024)01-0179-12

基于 prompt tuning 的中文文本多领域情感分析研究*

赵文辉[1],吴晓鸽[1],凌　捷[1],HOON Heo[2]
(1. 广东工业大学计算机学院,广东 广州 510006;2. 三星电机,韩国 水原 16674)

摘　要:不同领域的情感文本表达方式不一样,通常需要为各个领域训练相应的情感分析模型。针对无法用一个模型进行高效多领域情感分析的问题,提出了基于提示微调(prompt tuning)的多领域文本情感分析方法 MSAPT。借助 hard prompt,指示情感文本的所属领域和待选的情感标签,调动不同领域情感分析相关的知识,再为情感分析预训练一个统一的"通才模型",在下游的各领域文本学习中,保持模型冻结,通过 prompt tuning 使模型学习到下游各领域情感文本的特征。MSAPT 仅需保存一个模型和一些参数量远远小于模型的 prompt,实现了多领域情感分析。在多个属于不同领域的情感文本数据集上进行实验,结果表明仅进行 prompt tuning 时,MSAPT 效果优于模型微调(model tuning)的。最后,分别对适应特定领域的 prompt tuning、hard prompt、soft prompt 的长度和中间训练数据集的大小进行消融实验,从证明其对情感分析效果的影响。

关键词:多领域情感分析;提示微调;预训练语言模型;T5
中图分类号:TP391　　**文献标志码**:A
doi:10.3969/j.issn.1007-130X.2024.01.019

Multi-domain sentiment analysis of Chinese text based on prompt tuning

ZHAO Wen-hui[1], WU Xiao-ling[1], LING Jie[1], HOON Heo[2]
(1. School of Computer Science and Technology, Guangdong University of Technology, Guangzhou 510006, China;
2. Samsung Electro-mechanics, Suwon 16674, Korea)

Abstract: The expression of sentiment texts in different domains are different, so it is usually necessary to train the corresponding sentiment analysis model for each domain. In order to solve the problem that one model cannot be used for multi-domain sentiment analysis, this paper proposes a multi-domain text sentiment analysis method based on prompt tuning, called MSAPT. With the help of hard prompts, indicating the domain of the emotional text and the selected emotional labels, the model is prompted to draw on its knowledge of different domain sentiment analysis. Then, a unified "generalized model" is pretrained for sentimental analysis. In downstream learning of various domain texts, the model is frozen and prompt tuning is used to make the model learn the characteristics of emotional text in each downstream domain. MSAPT only requires saving a model and some prompts with far fewer parameters than the model for multi-domain sentiment analysis. Experiments were conducted using multiple datasets of emotional text in different fields, and the results show that MSAPT outperforms model fine-tuning when only prompted tuning is applied. Finally, the length of prompt tuning, hard prompt adapted to specific domains, soft prompt and the size of intermediate training dataset are ablated respectively, to prove their impact on the effectiveness of sentiment analysis.

* **收稿日期**:2022-06-20;**修回日期**:2022-12-14
基金项目:广东省国际科技合作领域项目(2019A050513010);工业装备质量大数据工业和信息化部重点实验室开放课题(2021-1EQBD-02)
通信作者:吴晓鸽(11009599@qq.com)
通信地址:510006 广东省广州市番禺区大学城广东工业大学计算机学院
Address: School of Computer Science and Technology, Guangdong University of Technology, Higher Education Mega Center, Panyu District, Guangzhou 510006, Guangdong, P. R. China

Key words:multi-domain sentiment analysis;prompt tuning;pre-trained language model(PLM);T5

1 引言

随着互联网的发展,人们生活的各个领域都与互联网产生了紧密的联系,人们会在各个互联网平台发表评论。通过分析这些文本中的情感倾向,挖掘有价值的信息,是自然语言处理中一个重要的研究方向。

目前情感分析方法主要基于情感词典、机器学习和深度学习。深度学习常用的神经网络模型有卷积神经网络 CNN(Convolutional Neural Network)、循环神经网络 RNN(Recurrent Neural Network)、长短期记忆 LSTM(Long Short-Term Memory)网络和门控循环单元 GRU(Gated Recurrent Unit)。这些模型均被广泛应用到情感分析任务中。Kalchbrenner 等[1]提出把 CNN 应用于自然语言处理,并设计了一个动态卷积神经网络模型,以处理不同长度的文本。Monika 等[2]提出使用循环神经网络模型 RNN 对序列信号进行建模,通过在网络模型中引入记忆单元来处理长期依赖关系,同时能避免 RNN 的梯度消失问题。

近年来,预训练语言模型 PLM(Pre-trained Language Model)飞速发展,相继提出了 BERT(Bidirectional Encoder Representations from Transformers)[3]、RoBERTa(Robustly optimized BERT pretraining approach)[4]和 T5[5]等基于 Transformer 的模型。因为 PLM 通过自注意力机制解决一词多义的问题,同时还能捕获词与词、句与句之间的高维情感特征,加上巨大的模型规模与从大规模预训练语料中获得的通用知识,微调 PLM 的全模型参数后进行情感分析取得了非常优异的性能,成为了情感分析的主流方法[6-8]。Man 等[9]提出使用 BERT 模型作为文章特征提取模型,并利用深度卷积神经网络提取文章的局部信息,效果好过传统深度学习模型的。梅侠峰等[10]提出了结合 ALBERT(A Lite BERT)和 BiFASRU-AT(Bidirectional built-in Fast Attention Simple Recurrent Unit-ATtention)的情感分析模型,借助预训练模型赋予词上下文动态语义,解决了一词多义问题;再采用双向内置快速注意力简单循环单元 BiFASRU 对上下文进行建模,模型获得了较高的 $F1$ 值。

然而,情感文本的表达方式与文本所属领域密切相关,不同领域的情感描述之间有着明显的差别。例如,“这真的把我看哭了。”这句话,描述一部电影可能是感动而哭的积极评价,而若是放在餐饮领域,则可能是因为菜品卖相太差的消极评价。因此,直接将某特定领域训练的情感分析模型应用于其它领域会存在适应度不佳的问题[11]。传统的模型微调(model tuning)方法对多个不同领域进行情感分析,需要对每个领域分别建模。比如,杨修远等[12]提出了一种自适应多领域知识蒸馏框架,分别训练多个不同领域的 BERT 教师模型;然后,利用基于多领域对应的多个 BERT 模型,对单个学生模型进行进一步的蒸馏学习。而训练各个领域对应的情感模型,需要保存每个领域对应的大量参数,这将会极大地耗费存储空间,如图 1a 所示。

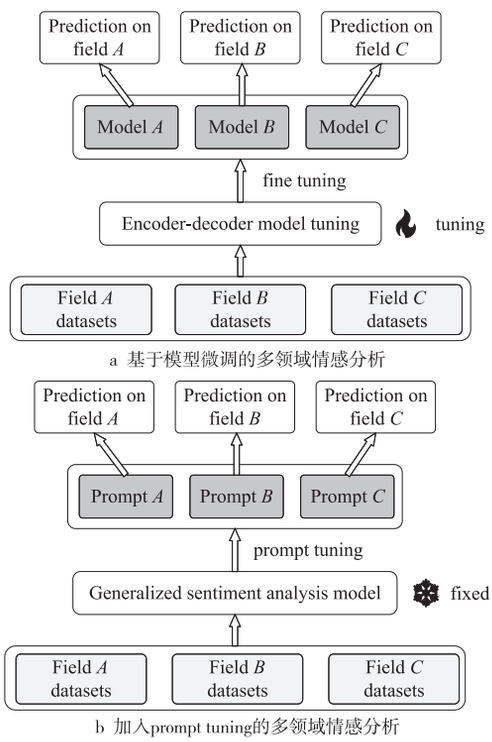

Figure 1 Comparison of multi-domain sentiment analysis methods based on model fine-tuning and prompt tuning

图 1 基于模型微调与基于提示微调的多领域情感分析方法对比

Brown 等[13]提出了 prompt design(或 priming),可通过给出任务描述或者几个范例来调动 GPT-3 模型,模型无需微调,可直接应用于下游任务。这种方法无需为每个下游任务训练相应的模型参数,单个模型可以同时服务于许多不同的任务。在当今模型参数量持续增加的情况下,“冻结”预训练模型的方法产生了巨大的影响。然而这种

通过人工设计的 prompt 和少量范例来调动模型的方法,在下游任务上的性能远远落后于模型微调的。

近期,有研究人员提出了自动生成(设计)prompt 的方法。Shin 等[14]提出了一种在下游任务训练数据的指导下,搜索多个离散的模型基本输入单元(token)组成 prompt 的算法。虽然这优于人工设计的 prompt,但其效果与模型微调的仍有差距。

Li 等[15]提出了前缀微调(prefix tuning)方法,冻结模型参数并在编码器中的每层加入了"前缀"。与人工设计和自动生成的 prompt 不同的是,"前缀"完全由可微调的自由参数组成,与离散的 token 不是一一对应的。此方法在生成任务上取得了优异的结果。后来,Hambardzumyan 等[16]将可训练参数仅添加到掩码语言模型(Masked Language Model)的输入和输出子网络中,简化了上述方法,在分类任务上取得了尚可的结果。

Lester 等[17]提出了 prompt tuning,进一步简化了 prompt 的形式,此方法保持模型冻结,仅仅把 k 个可微调的 token 添加到输入文本的前端作为 soft prompt,不同的下游任务学习不同的 soft prompt。当模型规模变得很大时,prompt tuning 的效果接近于模型微调的,但在中小型的模型中,prompt tuning 的效果与模型微调的还存在较大差距。值得注意的是,实验中发现,对 prompt 使用不同的初始化方法,对最终的效果有很大的影响。

因此,一些研究工作中提出,在 prompt 应用到下游任务之前,先用有监督或自监督学习的方法进行训练得到一个或几个 prompt,作为下游任务 prompt 的初始化,取得了非常好的效果。Gu 等[18]提出了 PPT(Pre-trained Prompt Tuning),通过自监督学习的方法训练 prompt 作为下游任务的初始化,在少样本学习(few-shot learning)中的效果显著。几乎同时,Vu 等[19]提出了 SPoT(Soft Prompt Transfer),首先在一个或多个有标注的数据集上训练 soft prompt,作为下游任务 prompt 的初始化,此方法在全量数据学习中效果优于模型微调的。但是,在应用于下游任务进行 prompt tuning 时,训练步数竟然达到了惊人的 2^{18}(262 144),需要耗费大量的计算资源,而且在训练步数较少时,SPoT 的效果与模型微调的还存在一定差距。

以上方法,要么效果无法与模型微调的媲美,要么训练步数过多导致耗费巨量的计算资源。因此,本文提出了 MSAPT(Multi-domain Sentiment Analysis approach based on Prompt Tuning),把 prompt tuning 进行适当调整,应用于多领域情感分析,并通过训练一个情感分析"通才模型",减少下游任务中的训练步数,同时保留其仅微调少量参数即可达到模型全参数微调效果的优点。

MSAPT 首先为情感分析的各个领域设计 hard prompt 添加到输入文本中,同时也添加 soft prompt,再为情感分析预训练一个统一的"通才模型",在下游的各领域文本学习中,保持模型冻结,通过提示微调(prompt tuning)使模型学习到各领域情感文本的特征,如图 1b 所示。因为预训练"通才模型"会被反复用到各个不同领域的情感分析任务中,所以 MSAPT 保持了 prompt tuning 参数高效的优点,仅需保存一个模型和一些参数量远远小于模型的 prompt。本文还设置了 4 个消融实验,分别对适应特定领域的 prompt tuning、hard prompt、soft prompt 的长度和中间训练数据集的大小进行消融,探索这 4 个因素对情感分析效果的影响。综上所述,本文的主要工作概括如下:

(1) 提出了 MSAPT,把 prompt tuning 进行适当调整后应用到多领域情感分析,仅保存一个模型和一些参数量远远小于模型的 prompt,即可进行高效的多领域情感分析,并且其效果能与模型微调的相媲美。

(2) 设计 hard prompt 帮助模型识别不同的情感领域,并提供了在特定情感领域中检索合适的 hard prompt 的方法。

(3) 在对下游各领域文本进行 prompt tuning 时,训练的轮次(epoch)数固定在 10,总共的训练步数控制在 1 960～17 980,在减少训练步数的同时,效果可与模型全参数微调的相媲美。

(4) 在消融实验中证明了添加 hard prompt、进行 prompt tuning 对改善情感分析效果存在显著作用;增加中间训练数据集的大小有助于提升方法在下游各领域情感分析任务中的效果;soft prompt 的长度对模型效果有显著影响。

2 基于 prompt tuning 的文本情感分析方法

本文遵循使用 T5 模型将 NLP(Natural Language Processing)任务统一为"text to text"形式的方法[5],同样把多领域情感分析转换为文本生成任务。对于 T5 的模型微调,通常将分类任务建模为 $Pr_\theta(Y \mid X)$,即给定输入文本 X,预测类标签

token 序列 Y 的概率,其中 θ 是 T5 模型由编码器和解码器[20]构成的 Transformer 模块的参数。

prompt 是添加在输入文本 X 前端的一系列 token,可看做是为模型预测 Y 输入的额外信息。prompt 可分为离散的 prompt 和连续的 prompt。人工设计或自动生成的 prompt 由模型词汇表中的 token 构成,其参数化为模型参数 θ 中词向量表的一部分,固定且不可微调。因此,寻找最佳的 prompt 需要通过人工设计或搜索算法来完成,这 2 种方法都不可微[21],所以它是离散的 prompt,或称为 hard prompt。

2.1 为输入文本添加 prompt

2.1.1 为输入文本添加 hard prompt

为了使模型能更好地学习到不同领域情感文本的特征,受到 hard prompt 可以将几个不同的任务统一为一个任务的启发[22],MSAPT 在输入文本 X 的前面添加了人工设计的 hard prompt,记为 H。hard prompt 表示该情感文本的所属领域和待选的情感标签,如一个电影领域三分类的情感文本的 H 可表示为:"领域:电影;标签:消极,适中,积极;文本:",如图 2b 所示。将标签词以多选的形式放入到 H 中,目的是增强 H 的可扩展性。未来随着分类类别的增多,可以将新增的情感标签添加到 H 中,比如细粒度情感分析的标签词"愤怒""开心""嫉妒"等。值得注意的是,MSAPT 以"领域:""标签:"和"文本:"3 个固定的词帮助模型区分输入中的不同信息,又因为 H 是添加在输入文本 X 之前的,所以在 H 的最后加上了"文本:"。同时,因为 H 由离散的 token 组成,所以由模型参数 θ 中词向量表的参数进行参数化,不可学习更新。在为输入文本添加 hard prompt 后,可将多领域情感分析任务建模为 $Pr_{\theta}(Y \mid [H;X])$。

2.1.2 为输入文本添加 soft prompt

连续的 prompt 消除了 prompt 由模型参数 θ 初始化的限制,可自由选择初始化形式,包括随机初始化、用词汇表中的高频词初始化和用标签词初始化等。关键是,连续的 prompt 的向量空间是连续的,所以它是可微的,可通过反向传播更新参数寻找最佳的 prompt。因为可微调,所以又称为 soft prompt。

得到一个"通才模型"后,为了能让模型在未知领域或数据集中学习到相应的情感文本特征,MSAPT 在输入文本和 hard prompt 前面添加了 soft prompt,记为 P,如图 2b 所示。P 的参数独立于 T5 模型,而且可通过学习更新,记为 θ_P。在为输入文本添加 soft prompt 后,可将多领域情感分析任务建模为 $Pr_{\theta;\theta_P}(Y \mid [P;H;X])$。

2.1.3 输入矩阵

输入一个含有 n 个 token 的句子 $\{x_1,x_2,\cdots,x_n\}$,T5 模型首先把这些 token 向量化,形成一个矩阵 $\boldsymbol{X}_e \in \mathbf{R}^{n\times e}$,其中 e 是词向量的维度。然后将 soft prompt 参数化为矩阵 $\boldsymbol{P}_e \in \mathbf{R}^{p\times e}$,其中 p 是 soft prompt 的长度;将 hard prompt 参数化为矩阵 $\boldsymbol{H}_e \in \mathbf{R}^{h\times e}$,其中 h 是 hard prompt 的长度。最后将 $\boldsymbol{P}_e$、$\boldsymbol{H}_e$、$\boldsymbol{X}_e$ 依次连接,形成单个矩阵 $[\boldsymbol{P}_e;\boldsymbol{H}_e;\boldsymbol{X}_e] \in \mathbf{R}^{(p+h+n)\times e}$ 作为最终的输入,经过编码器和解码器最终输出 Y,如图 3 所示。

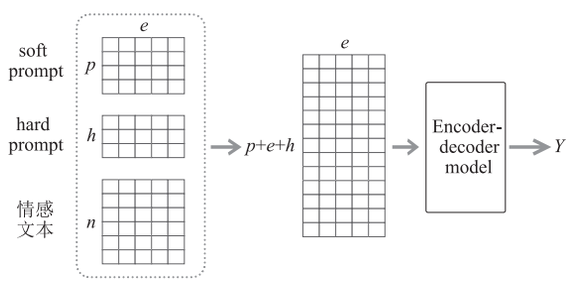

Figure 3 Formation of input matrix

图 3 形成输入矩阵

2.2 多领域情感分析方法

通过 $Pr_{\theta;\theta_P}(Y \mid [P;H;X])$ 可以看出,MSAPT 目标是通过优化参数 θ 和 θ_P,最大化预测正确 Y 的概率。为了提高 prompt tuning 的性能,并且减少 soft prompt 在下游各领域情感分析任务中的训练步数,本文改进了 SPoT 方法,将模型训练分为了 2 个阶段。第 1 个阶段训练"通才模型",不冻结模型任何参数,即 θ 和 θ_P 都进行更新。

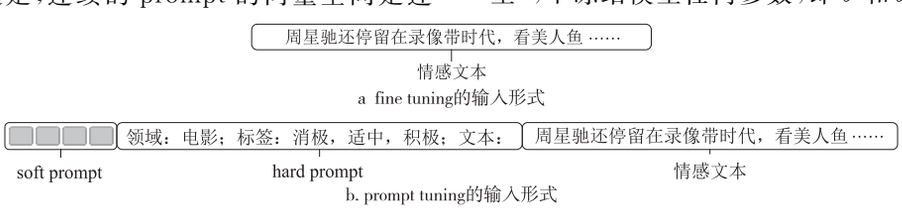

Figure 2 Comparison of input forms of multi-domain sentiment analysis based on model fine tuning and prompt tuning

图 2 基于模型微调与基于 prompt tuning 的多领域情感分析输入形式对比

第 2 个阶段应用到下游特定领域或数据集,冻结模型参数 θ ,仅更新 θ_P ,即 prompt tuning。prompt tuning 因为微调的参数较少,具有拟合慢的特点。在第 1 阶段训练“通才模型”拟合情感分析的通用知识,在 prompt tuning 阶段仅需拟合特定领域的情感特征,从而可以减少 prompt tuning 步数,且不会导致对情感特征的欠拟合。

多领域情感分析方法流程如图 4 所示。首先,为训练“通才模型”准备大量的情感分析文本,并加入 soft prompt 和 hard prompt,为了方便下文阐述,把修改后的数据集命名为中间训练数据集。接着,在语言模型预训练和对下游各领域情感分析任务进行 prompt tuning 之间加入一个中间训练阶段,基于中间训练数据集,把原 T5 模型训练为一个无特定领域的情感分析“通才模型”。但是,必须强调的是,若此时直接应用于下游任务,还无法达到模型微调的效果,详见本文 4.1 节。与 SPoT 方法不同,本文方法在这个阶段没有冻结 T5 模型,对 θ 和 θ_P 都在进行更新。最后,在应用到下游各领域的情感分析任务时,先将在交叉验证集上表现最好的 hard prompt 加入到文本中,并且冻结模型参数 θ ,仅微调 θ_P ,即通过 prompt tuning 学习该领域的文本情感特征,因为在这个过程中模型参数不变,所以只需要存储训练好的特定于该领域的 soft prompt 而不是整个模型的参数,即一个领域存储一个 soft prompt。

MSAPT 保留了 prompt tuning 的优点,因为其反复利用一个统一的“通才模型”,只需为下游各领域或特定数据集选择适合的 hard prompt,训练并存储特定于各领域的 soft prompt,即用一个固定的模型和一些参数量很小的 soft prompt 进行多领域的情感分析。若设置 soft prompt 的长度 $p=50$,则其参数量为 $768\times50=38400$。base 版本的 T5 参数量约为 2.4 亿,所以 soft prompt 的参数量仅为模型参数量的 1.5‰。

3 实验与结果分析

本文对游戏、外卖、书籍、衣服和酒店等多个领域的文本进行情感极性预测,涉及的数据集介绍详见 3.1.2 节。传统微调方法需要为每个领域训练相应的模型参数,耗费存储空间。MSAPT 先通过中间训练数据集训练一个“通才模型”,再通过 prompt tuning 学习上述各领域相应的情感特征。

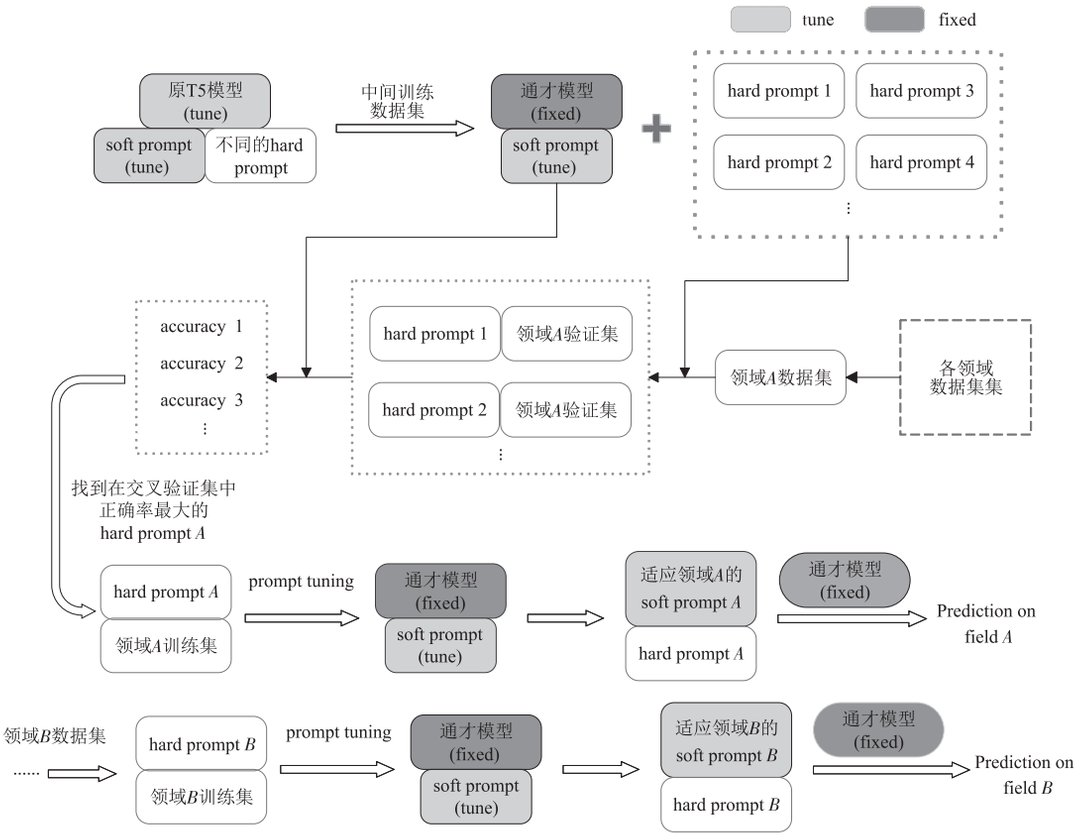

Figure 4 Flow chart of multi-domain sentiment analysis method

图 4 多领域情感分析方法流程图

3.1 实验设置

本文实验的 T5 模型使用澜舟科技开源的中文预训练语言模型 Langboat/mengzi-t5-base[23]，模型版本为 base。本节中的所有 soft prompt 的长度 p 都设置为 50。

3.1.1 “通才模型”的训练数据

为了训练一个情感分析的通用模型，本文构建了一个由 174 万条情感分析数据组成的数据集，即中间训练数据集。这个数据集由公开的 simplify-weibo_4_moods、yf_amazon、yf_dianping 和 douban_movies 数据集组成。通过有监督学习使原 T5 模型转换为一个适用于各领域的情感分析“通才模型”。

3.1.2 测试数据与评价标准

为了验证本文方法的有效性，分别评估了 MSAPT 在全量数据学习和少样本学习 2 种情况下的效果。在实验过程中发现，若从中间训练数据集中随机筛选一部分样本用于评估测试，因为模型在这些领域已经进行了大量的学习，效果远好于模型微调的。所以，为了增强实验结果的说服力，本文避免使用上述数据进行评估测试。全量数据采用的数据集有：online_shopping_10_cats、game-taptap、waimai_10k、NLPCC14-SC、ASAP_SENT 和 ChnSentiCorp[24]。少样本学习采用的数据集是 EPRSTMT[25]。本文分别就 32 个样本和 160 个样本的情况进行了测试。二分类任务的极性标签为消极和积极，三分类任务增加适中(neutral)情感标签。测试数据集涉及的情感领域有游戏、外卖、微博、衣服、手机、水果、电脑、书籍、DVD、牛奶和酒店等。本文把这些数据集都划分为训练集、交叉验证集和测试集。对于一些标签为分数的数据集，则转换为三分类的情感分析任务。

因为数据集中各类情感样本数量基本平衡，所以本文直接采用正确率来评估各方法在数据集上的效果，并计算每种方法的分数。

为了方便直观地看出每种方法的效果，本文定义了一个分数，表示一种方法相对于被比较的所有方法的平均性能提升了多少，计算方法如图 5 所示。假设有 3 种方法：M_1、M_2、M_3，有 3 个测试数据集 T_1、T_2、T_3，a_{xy} 表示在数据集 T_x 上方法 M_y 的正确率，$x,y\in\{1,2,3\}$。首先计算 T_1、T_2、T_3 上所有方法的平均正确率$\{A_1,A_2,A_3\}$，如图 5a 所示；再计算 M_1、M_2、M_3 在 T_1、T_2、T_3 上相对平均正确率提升的百分比，并计算每种方法的平均值即为 M_1、M_2、M_3 的分数 S_{M1}、S_{M2}、S_{M3}，如图 5b 和图 5c 所示。本文认为在各个测试集的正确率相差较大时，分数相比直接计算平均正确率更能代表方法的性能。

3.1.3 基线方法

本文将所提出的 MSAPT 与以下微调方法进行对比：

(1)随机初始化的 prompt tuning：随机初始化 soft prompt，直接在测试数据集上训练，下文记为 RIPT (Random Initialization Prompt Tuning)。

(2)SA-SPoT(Sentiment Analysis SPoT)：将 SPoT 应用于多领域情感分析，通过中间训练数据集训练一个 soft prompt，作为应用在测试数据集上的 soft prompt 的初始化(训练 epoch 数也固定为 10)。

(3)model tuning：模型微调是优化模型的标准方法，模型的全部参数都会更新。本文将 MSAPT 与 T5、BERT、RoBERTa 3 种模型的全参数微调方法进行对比。为了对比的公平性，BERT 和 RoBERTa 也采用了 base 版本。BERT 采用 hugging face 的 Transformers 库中开源的“bert-base-chinese”版本。RoBERTa 采用哈工大讯飞联合实验室开源的“RoBERTa-wwm-ext”版本[26]。

3.1.4 实验环境与参数选取

本文实验环境参数如表 1 所示。

在全量样本(full sample)测试数据集上的训练参数设置如下：对于 MSAPT、RIPT 和 SA-

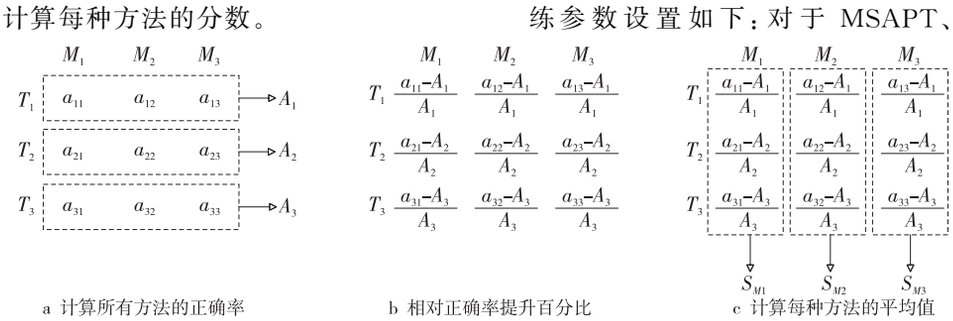

a 计算所有方法的正确率　　b 相对正确率提升百分比　　c 计算每种方法的平均值

Figure 5 Computing method of the score

图 5 分数的计算方法

SPoT,在测试数据集上固定进行 10 个 epoch 的训练,初始学习率为 5e−2,预热比例为 0,批处理大小为 20,优化器为 AdamW[27],损失函数为交叉熵函数;对于 model tuning,在测试数据集上固定进行 3 个 epoch 的训练;BERT 和 RoBERTa 初始学习率为 1e−5,T5 初始学习率为 1e−4,预热比例为 0.1,批处理大小为 20,优化器为 AdamW,损失函数为交叉熵函数。每一轮保存一个 checkpoint,选用在交叉验证集上正确率最大的 checkpoint 在测试集上测试,将测试结果作为最终结果。

Table 1 Experimental environment parameters

表 1 实验环境参数

参数名称	参数值
GPU	NVIDIA® GeForce RTX™ 3090
处理器	Intel® Xeon® Gold 6130
操作系统	Centos 7.3
显存	24 GB
开发语言	Python
深度学习框架	PyTorch

在少样本测试数据集上的训练参数除了 epoch 数和批处理大小不一样外,其他与在全量样本测试数据集上的训练参数保持一致。对于 MSAPT、RIPT 和 SA-SPoT,训练 epoch 为 100,批处理大小为 8。对于 model tuning,训练 epoch 为 8,批处理大小为 16。

在中间训练数据集上的训练参数设置如下:对于 MSAPT,初始学习率为 1e−4,预热比例为 0,批处理大小为 16,优化器为 AdamW,损失函数为交叉熵函数;对于 SA-SPoT,初始学习率为 5e−2,预热比例为 0,批处理大小为 20,优化器为 AdamW,损失函数为交叉熵函数。

3.2 实验结果及分析

为确保实验的可对比性,降低随机误差,本文选取 3 次冷启动实验的平均结果作为最终实验结果。

3.2.1 全量样本学习的结果与分析

本节比较了 6 种方法在 6 个全量样本数据集上的表现,结果如表 2 所示。在表 2 中,分别用加粗和下划线突出性能最佳和次佳的方法。

从表 2 可以看出:

(1)本文提出的 MSAPT 在 3 个数据集上获得了最佳的性能,分数在 6 种方法中第二高,稍低于 RoBERTa 模型微调的,但超过了 T5 和 BERT 模型微调的。

(2)SA-SPoT 在比较少的训练步数下,平均效果相比随机初始化的 prompt tuning 提高了 3.05%,但仍无法达到模型微调的效果。MSAPT 改进了 SA-SPoT 方法训练步数过多的问题,依靠"通才模型"对通用文本情感特征进行拟合,解决了 SA-SPoT 方法欠拟合的问题,在较少的训练步数下能达到甚至超过一部分模型微调的效果。

本文提出的 MSAPT 在对游戏、外卖、书籍、衣服和酒店等多个领域的文本进行情感极性预测时,先通过"通才模型"对通用文本情感特征进行拟合,再进行 prompt tuning,以适应各领域的情感特征,从而提高预测准确率。如表 3 所示,模型在学习游戏领域特有的文本情感特征前,会将带有很多正向词汇的语句预测为积极评论(错误),而在对该领域 prompt tuning 后,则能分辨出该评论指示游戏为抄袭,转而预测为消极评价(正确)。同样地,剩下的领域中也存在大量的这种情况。prompt tuning 拟合各领域情感特征后能纠正"通才模型"的错误预测结果,提高预测准确率。可见,MSAPT 仅需保存一个模型和一些参数量远小于模型的 soft prompt,其效果就能媲美甚至超过模型微调的。

3.2.2 少量样本学习的结果与分析

本节比较了6种方法在2个少样本数据集上

Table 2 Experimental results based on full sample learning

表 2 基于全量样本学习的实验结果 %

	fine tuning			prompt tuning		
	T5	RoBERTa	BERT	RI	SA-SPoT	MSAPT
online_shopping_10_cats	95.99	96.06	96.06	95.15	95.30	**96.19**
game-taptap	81.39	**84.87**	82.82	67.08	78.53	84.25
waimai_10k	89.91	90.33	**91.08**	88.74	89.24	90.58
NLPCC14-SC	83.30	83.90	83.10	81.10	82.10	**84.40**
ASAP_SENT	83.04	83.85	83.24	82.39	82.94	**85.10**
ChnSentiCorp	92.50	**95.25**	93.92	89.17	90.42	93.58
分数	0.340	1.933	1.123	−4.184	−1.138	1.925

Table 3 Comparison of predicted results of sentiment polarity before and after using prompt tuning

表 3 prompt tuning 前后情感极性预测结果对比

领域	评论	prompt tuning 前	prompt tuning 后
游戏	我的世界生存战争,这个名字很有"新意",肯定不是把 2 个游戏名字合起来的。还有那饥荒一样的玩法,真是优秀!	积极(×)	消极(√)
书籍	看这本书时一直在反复听《The long and winding road》,悲怆苍凉的声音和黑暗绝望的剧情很搭。	消极(×)	积极(√)
外卖	快递很不错。饭没啥味道!! 太淡了!!	积极(×)	消极(√)
酒店	宾馆周围环境不错,离商业区很近,而且幽静。不过宾馆有些老了,装修都过时了。	消极(×)	积极(√)

的表现,结果如表 4 所示。

通过分析表 4 可以得出以下结论:

(1)无论是在 32 个还是 160 个样本的数据集上,MSAPT 都获得了最佳的效果。因为 SA-SPoT 和 MSAPT 都经过了大量情感分析数据的训练,受益于迁移学习,在少样本学习中表现很好。值得注意的是,MSAPT 的效果依然比 SA-SPoT 的好。

(2)MSAPT 在少样本学习的多领域文本情感分析任务中依然表现优秀,效果远好于模型微调的。

4 消融实验

本节设置了 4 个消融实验,分别对适应特定领域的 prompt tuning、hard prompt、soft prompt 的长度和中间训练数据集的大小进行消融,探索这 4 个因素在 MSAPT 中对情感分析效果的影响。除了 soft prompt 长度的消融实验外,其他消融实验均设置 soft prompt 的长度 $p=50$。除了 4.1 节中的实验,本节其它实验均在中间训练数据集上训练过,所以本节把从中间训练数据集分割出来的 2 个数据集加入到 4.2 节~4.4 节测试评估使用的数据集中,这 2 个数据集涉及的领域分别是电影和大众点评。

4.1 prompt tuning 的消融实验

本节设置了 3 组实验。第 1 组是"通才模型"(在中间训练数据集上训练出的适用于各领域的情感分析统一模型)直接应用于下游各领域情感分析任务,而不进行适应特定领域文本情感特征的 prompt tuning。第 2 组是先把下游的 6 个不同领域情感分析数据集的训练集和交叉验证集融合为一个大的下游情感分析数据集,用原 T5 模型在此数据集上进行模型全参数微调,并选出交叉验证集上效果最好的,分别在 6 个数据集的测试集上进行测试。第 3 组实验将第 2 组实验的原 T5 模型换为"通才模型",其它设置均与第 2 组的相同。因为 MSAPT 的优点是利用一个统一模型进行各领域情感分析而无需保存多个大模型,所以设置第 2 组和第 3 组实验的目的是:验证在只有一个统一模型的情况下,prompt tuning 的效果(MSAPT 的)好于模型直接在各领域集合的数据集上训练(第 2 组和第 3 组的)。

各组实验结果如图 6a 所示,分数如表 5 所示,各个数据集上的详细结果见表 6。通过分析可知,直接把"通才模型"应用于下游各领域的效果是最差的,但这也展现了"通才模型"强大的零样本学习能力。将原 T5 模型在 6 个数据集组成的大数据集上训练,其效果稍好于 T5 模型在各个数据集上训练的效果,但若要应用到新领域的数据集,则需重新训练模型,可扩展性差。虽然第 3 组实验受益于迁移学习[28,29],效果好于第 2 组的,但仍然不及 prompt tuning 的效果,同样具有可扩展性差的缺点。可见,MSAPT 不仅能更方便地应用到不同领域的情感分析任务中(冻结模型参数),而且能使模型更好地适应下游各领域的情感文本特征。

Table 5 Score of each group of prompt tuning ablation experiments

表 5 prompt tuning 的消融实验各组分数表

方法	分数/%
第 1 组	0.209
第 2 组	−2.196
第 3 组	0.722
MSAPT	**1.265**

4.2 hard prompt 的消融实验

为了证明在文本中添加 hard prompt 能提高方法性能,本节设置了一组不添加 hard prompt 的

Table 4 Experimental results based on few-shot learning

表 4 基于少量样本学习的实验结果 %

Dataset	fine tuning			prompt tuning		
	T5	RoBERTa	BERT	RI	SA-SPoT	MSAPT
EPRSTMT(32)	83.44	63.93	72.62	58.85	90.00	**91.64**
EPRSTMT(160)	87.21	85.57	84.92	88.52	90.33	**91.80**

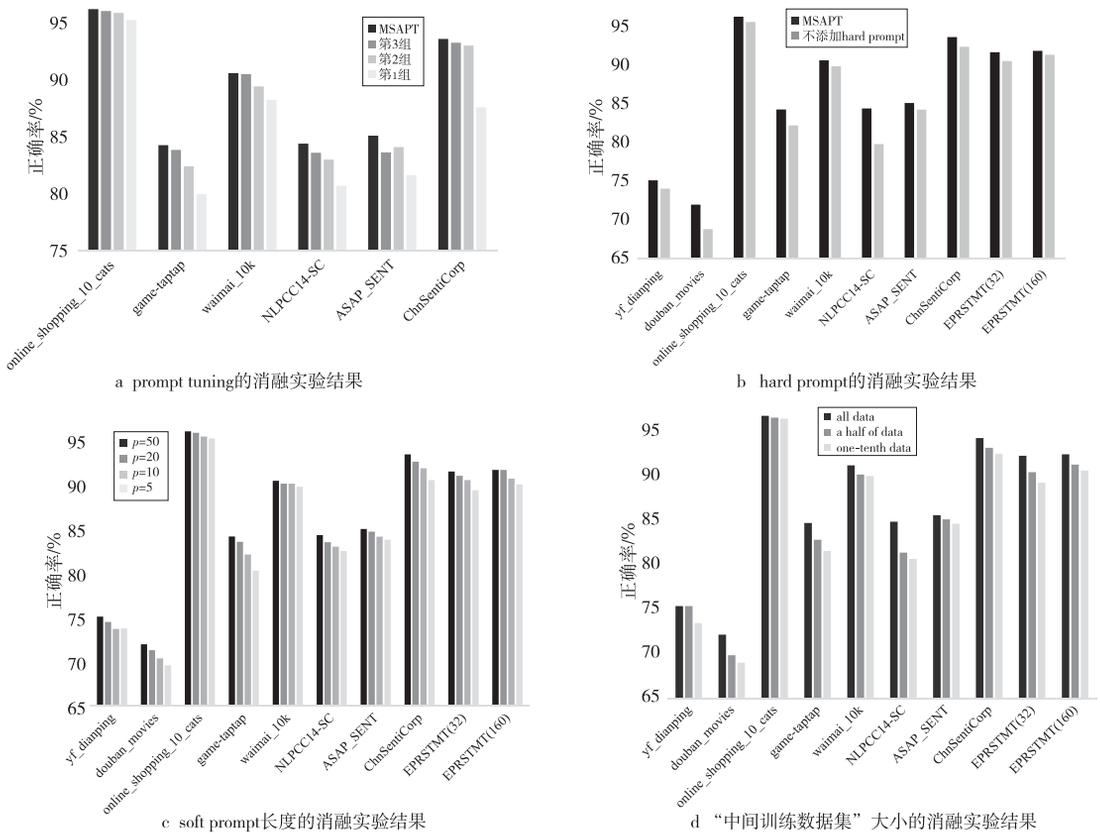

Figure 6 Results of ablation experiment on each dataset

图 6 消融实验在各组数据集上的结果

Table 6 Results of ablation experiments of prompt tuning

表 6 prompt tuning 的消融实验结果 %

Dataset	MSAPT	第 3 组	第 2 组	第 1 组
online_shopping_10_cats	**96.19**	96.04	95.86	95.24
game-taptap	**84.25**	83.84	82.41	79.96
waimai_10k	**90.58**	90.49	89.41	88.24
NLPCC14-SC	**84.40**	83.60	83.00	80.70
ASAP_SENT	**85.10**	83.62	84.09	81.62
ChnSentiCorp	**93.58**	93.25	93.00	87.58
分数	**1.265**	0.722	0.209	−2.196

实验,并在全量数据集和少样本数据集上进行了测试。实验结果如图 6b 所示,分数如表 7 所示,各个数据集上的详细结果见表 8。通过分析可知,在文本中添加 hard prompt 能显著提升方法的效果,因为其能指示情感文本的所属领域和待选的情感标签,有利于调动模型这一部分的知识。

Table 7 Score of hard prompt ablation experiments

表 7 hard prompt 消融实验分数

方法	分数/%
MSAPT	0.801
不添加 hard prompt	−0.801

Table 8 Results of hard prompt ablation experiments

表 8 hard prompt 消融实验结果 %

Dataset	MSAPT	不添加 hard prompt
yf_dianping	75.13	74.07
douban_movies	72.00	68.87
online_shopping_10_cats	96.19	95.53
game-taptap	84.25	82.21
waimai_10k	90.58	89.82
NLPCC14-SC	84.40	79.80
ASAP_SENT	85.10	84.23
ChnSentiCorp	93.58	92.33
EPRSTMT(32)	91.64	90.49
EPRSTMT(160)	91.80	91.31
分数	0.801	−0.801

4.3 soft prompt 长度的消融实验

本节设置了 3 组实验,分别把 soft prompt 的长度 p 设置为 5,10 和 20,其它实验设置保持不变,目的是探索 soft prompt 长度对方法效果的影响。实验结果如图 6c 所示,分数如表 9 所示,各个数据集上的详细结果见表 10。通过分析可知,soft prompt 的长度对 MSAPT 的效果存在比较显著的影响,当 soft prompt 的长度从 20 增加到 50 的时

候,方法效果仍有比较明显的提升。相比 Lester 等[17]的方法,MSAPT 在 soft prompt 长度超过 20 时,不是只会产生边际收益,而是仍然存在较大的性能提升,原因是训练步数固定且较少,同时减少训练参数会导致对下游领域的情感特征欠拟合,所以 MSAPT 中增加 soft prompt 的长度非常有必要。

Table 9 Scores of hard prompt ablation experiments

表 9 soft prompt 长度消融实验分数

p	分数/%
50	0.882
20	0.402
10	−0.286
5	−0.997

Table 10 Results of ablation experiments of the length soft prompt

表 10 soft prompt 长度的消融实验结果 %

Dataset	$p=50$	$p=20$	$p=10$	$p=5$
yf_dianping	75.13	74.53	73.73	73.80
douban_movies	72.00	71.33	70.40	69.60
online_shopping_10_cats	96.19	96.04	95.62	95.39
game-taptap	84.25	83.64	82.21	80.37
waimai_10k	90.58	90.24	90.24	89.91
NLPCC14-SC	84.40	83.60	83.10	82.60
ASAP_SENT	85.10	84.80	84.23	83.89
ChnSentiCorp	93.58	92.75	92.00	90.67
EPRSTMT(32)	91.64	91.15	90.66	89.51
EPRSTMT(160)	91.80	91.80	90.82	90.16
分数	0.882	0.402	−0.286	−0.997

通过分析还发现,当 soft prompt 的长度从 5 增加到 10 和从 10 增加到 20 的时候,方法效果提升较大,而从 20 增加到 50 的时候,提升幅度减小,这说明在 MSAPT 中 soft prompt 增加到一定长度以后再增加长度,也会像 Lester 等[17]的方法一样,只会产生边际收益。

4.4 中间训练数据集大小的消融实验

为了探究中间训练数据集大小对 MSAPT 性能的影响,本节设置了 2 组实验,分别把中间训练数据集的大小调整为原来的 1/2 和 1/10,其它实验条件保持一致,在全量数据集和少样本数据集上进行了测试。实验结果如图 6d 所示,分数如表 11 所示,各个数据集上的详细结果见表 12。

通过分析可知,增加中间训练数据集的大小,能提升 MSAPT 的性能,其原因是更大的中间训练数据集能使模型学习到更多情感分析的知识,能更好地泛化到各领域情感分析任务中。

Table 11 Scores of ablation experiments of the size of intermediate training dataset

表 11 中间训练数据集大小的消融实验各组分数

Data size	分数/%
all data	1.152
a half of data	−0.185
one-tenth data	−0.967

Table 12 Results of ablation experiments of the size of intermediate training dataset

表 12 中间训练数据集大小的消融实验结果 %

Dataset	all data	a half of data	one-tenth data
yf_dianping	75.13	75.13	73.27
douban_movies	72.00	69.73	68.93
online_shopping_10_cats	96.19	95.82	95.70
game-taptap	84.25	82.41	81.19
waimai_10k	90.58	89.57	89.41
NLPCC14-SC	84.40	81.00	80.30
ASAP_SENT	85.10	84.66	84.17
ChnSentiCorp	93.58	92.50	91.83
EPRSTMT(32)	91.64	89.84	88.69
EPRSTMT(160)	91.80	90.66	90.00
分数	1.152	−0.185	−0.967

5 结束语

本文提出了一种基于 prompt tuning 的多领域情感分析方法 MSAPT,并在多个数据集上验证了该方法的效果。在全量数据学习和少样本学习的多领域中文文本情感分析任务中,保持模型冻结,仅在下游各领域情感分析任务中学习各领域适应的 soft prompt,保存一个模型和一些参数量远远小于模型的 prompt,即可进行高效的多领域情感分析,效果媲美甚至超过模型微调的。相比于把一个模型在多个领域的数据集上训练,MSAPT 不仅效果更好,而且具有易扩展的优点。在文本中添加 hard prompt,指示情感文本的所属领域和待选的情感标签,有利于调动模型这一部分的知识,提升方法的效果。其次,soft prompt 的长度对 MSAPT 的情感分析效果存在比较显著的影响,不过仍然会在到达特定长度后,仅产生边际效益。通过增加中间训练数据集的大小,能使模型学习到更多情感分析的知识,更好地泛化到各领域情感分析任务中,提升 MSAPT 的性能。本文仅在句子级

情感分类任务上进行了实验。在接下来的工作中,将尝试将模型应用到方面级的情感任务中,还将尝试探索在 soft prompt 长度较短时,通过其他方法使其效果逼近 soft prompt 长度较长时的效果。

参考文献:

[1] Kalchbrenner N, Grefenstette E, Blunsom P. A convolutional neural network for modeling sentences[C]//Proc of the 52nd Annual Meeting of the Association for Computational Linguistics, 2014:655-665.

[2] Monika R,Deivalakshmi S,Janet B. Sentiment analysis of US airlines tweets using LSTM/RNN[C]//Proc of 2019 IEEE 9th International Conference on Advanced Computing,2019:92-95.

[3] Devlin J,Chang M W,Lee K,et al. BERT:Pre-training of deep bidirectional transformers for language understanding [C]//Proc of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies,2019:4171-4186.

[4] Liu Z,Lin W,Shi Y,et al. RoBERTa:A robustly optimized BERT pretraining approach[J]. arXiv:1907.11692,2019.

[5] Raffel C,Shazeer N,Roberts A,et al. Exploring the limits of transfer learning with a unified text-to-text transformer[J]. Journal of Machine Learning Research,2021,21(140):1-67.

[6] Howard J,Ruder S. Universal language model fine-tuning for text classification[C]//Proc of the 56th Annual Meeting of the Association for Computational Linguistics, 2018: 328-339.

[7] 黄泽民,吴晓鸽,吴迎岗,等. 结合 BERT 和 BiSRU-AT 的中文文本情感分类[J]. 计算机工程与科学,2021,43(9):1668-1674.
Huang Ze-min,Wu Xiao-ling,Wu Ying-gang,et al. Analysis of Chinese text emotions combining BERT and BiSRU-AT [J]. Computer Engineering & Science,2021,43(9):1668-1674.

[8] 王春东,张卉,莫秀良,等. 微博情感分析综述[J]. 计算机工程与科学,2022,44(1):165-175.
Wang Chun-dong,Zhang Hui,Mo Xiu-liang,et al. Overview on sentiment analysis of microblog[J]. Computer Engineering & Science,2022,44(1):165-175.

[9] Man R,Lin K. Sentiment analysis algorithm based on BERT and convolutional neural network[C]//Proc of 2021 IEEE Asia-Pacific Conference on Image Processing,Electronics and Computers,2021:769-772.

[10] 梅侠峰,吴晓鸽,吴杰文,等. 结合 ALBERT 和 BiFASRU-AT 的情感分析模型[J]. 小型微型计算机系统,2023,44(1):36-42.
Mei Xia-feng,Wu Xiao-ling,Wu Jie-wen,et al. Sentiment analysis model combined with ALBERT and BiFASRU-AT [J]. Journal of Chinese Computer Systems,2023,44(1):36-42.

[11] 赵传君,王素格,李德玉. 跨领域文本情感分类研究进展[J]. 软件学报,2020,31(6):1723-1746.
Zhao Chuan-jun,Wang Su-ge,Li De-yu. Research progress on cross-domain text sentiment classification[J]. Journal of Software,2020,31(6):1723-1746.

[12] 杨修远,彭韬,杨亮,等. 基于知识蒸馏的自适应多领域情感分析[J]. 山东大学学报(工学版),2021,51(3):15-21.
Yang Xiu-yuan, Peng Tao, Yang Liang, et al. Adaptive multi-domain sentiment analysis based on knowledge distillation[J]. Journal of Shandong University (Engineering Science),2021,51(3):15-21.

[13] Brown T,Mann B,Ryder N,et al. Language models are few-shot learners[C]//Proc of the 34th International Conference on Neural Information Processing Systems, 2020: 1877-1901.

[14] Shin T,Razeghi Y,Logan I R L,et al. Auto prompt:Eliciting knowledge from language models with automatically generated prompts[C]//Proc of the 2020 Conference on Empirical Methods in Natural Language Processing, 2020: 4222-4235.

[15] Li X L, Liang P. Prefix-tuning: Optimizing continuous prompts for generation[C]//Proc of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing,2021:4582-4597.

[16] Hambardzumyan K,Khachatrian H,May J. WARP:Word-level adversarial reprogramming[C]//Proc of the 59th Annual Meeting of the Association for Computational Linguistics and the 11th International Joint Conference on Natural Language Processing,2021:4921-4933.

[17] Lester B, Al-Rfou R,Constant N. The power of scale for parameter-efficient prompt tuning [J]. arXiv:2104.08691, 2021.

[18] Gu Y,Han X,Liu Z, et al. PPT:Pre-trained prompt tuning for few-shot learning[J]. arXiv:2109.04332,2021.

[19] Vu T,Lester B,Constant N,et al. SPoT:Better frozen model adaptation through soft prompt transfer[J]. arXiv:2110.07904,2021.

[20] Vaswani A,Shazeer N,Parmar N,et al. Attention is all you need[C]//Proc of the 31st International Conference on Neural Information Processing Systems,2017:6000-6010.

[21] Jiang Z,Xu F F,Araki J,et al. How can we know what language models know? [J]. Transactions of the Association for Computational Linguistics,2020,8:423-438.

[22] Zhong R,Lee K,Zhang Z,et al. Adapting language models for zero-shot learning by meta-tuning on dataset and prompt collections[J]. arXiv:2104.04670,2021.

[23] Zhang Z,Zhang H,Chen K,et al. Mengzi:Towards lightweight yet ingenious pre-trained models for Chinese[J]. arXiv:2110.06696,2021.

[24] Tian H,Gao C,Xiao X,et al. SKEP:Sentiment knowledge enhanced pre-training for sentiment analysis[C]//Proc of the 58th Annual Meeting of the Association for Computational Linguistics,2020:4067-4076.

[25] Xu L,Hu H,Zhang X,et al. CLUE:A Chinese language understanding evaluation benchmark[C]//Proc of the 28th International Conference on Computational Linguistics,2020: 4762-4772.

[26] Cui Y M,Che W X,Liu T,et al. Pre-training with whole word masking for Chinese BERT[J]. IEEE/ACM Transactions on Audio,Speech,and Language Processing,2021,29:3504-3514.

[27] Loshchilov I,Hutter F. Decoupled weight decay regularization[C]//Proc of the 2019 International Conference on Learning Representations,2019:935-942.

[28] 曲昭伟,王源,王晓茹. 基于迁移学习的分层注意力网络情感分析算法[J]. 计算机应用,2018,38(11):3053-3062.
Qu Zhao-wei,Wang Yuan,Wang Xiao-ru. Transfer learning based hierarchical attention neural network for sentiment analysis[J]. Journal of Computer Applications,2018,38(11):3053-3062.

[29] 余传明. 基于深度循环神经网络的跨领域文本情感分析[J]. 图书情报工作,2018,62(11):23-34.
Yu Chuan-ming. A cross-domain text sentiment analysis based on deep recurrent neural network[J]. Library and Information Service,2018,62(11):23-34.

作者简介:

赵文辉(1997 -),男,广东东莞人,硕士生,研究方向为自然语言处理和文本分类。**E-mail**:535569907@qq.com

ZHAO Wen-hui, born in 1997, MS candidate, his research interests include natural language processing and text classification.

吴晓鸰(1979 -),女,湖南汨罗人,博士,副教授,CCF 会员(E200048791M),研究方向为数据挖掘和信息安全。**E-mail**:11009599@qq.com

WU Xiao-ling, born in 1979, PhD, associate professor, CCF member (E200048791M), her research interests include data mining and information security.

凌捷(1964 -),男,广东梅州人,博士,教授,CCF 会员(33834M),研究方向为网络信息安全。**E-mail**:jling@gdut.edu.cn

LING Jie, born in 1964, PhD, professor, CCF member (33834M), his research interest includes network information security.

HOON Heo(1970 -),男,韩国水原人,博士,研究员,研究方向为自然语言处理和图像处理。**E-mail**:hoon97.heo@samsung.com

HOON Heo, born in 1970, PhD, research fellow, his research interests include natural language processing and image processing.