

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC KINH TẾ THÀNH PHỐ HỒ CHÍ MINH

NGUYỄN HỮU TUẤN

KHUNG PHƯƠNG PHÁP PHÂN TÍCH SẮC THÁI CẢM XÚC
CỦA NGƯỜI DÙNG VIỆT NAM TRÊN NỀN TẢNG YOUTUBE
DỰA TRÊN KIẾN TRÚC TRANSFORMER

LUẬN VĂN THẠC SĨ

Thành phố Hồ Chí Minh - Năm 2026

BỘ GIÁO DỤC VÀ ĐÀO TẠO
ĐẠI HỌC KINH TẾ THÀNH PHỐ HỒ CHÍ MINH

NGUYỄN HỮU TUẤN

KHUNG PHƯƠNG PHÁP PHÂN TÍCH SẮC THÁI CẢM XÚC
CỦA NGƯỜI DÙNG VIỆT NAM TRÊN NỀN TẢNG YOUTUBE
DỰA TRÊN KIẾN TRÚC TRANSFORMER

Chuyên ngành: Công nghệ thiết kế thông tin và truyền thông

Hướng đào tạo: Ứng dụng

Mã số: 8340405

LUẬN VĂN THẠC SĨ

NGƯỜI HƯỚNG DẪN KHOA HỌC:

NGÔ TẤN VŨ KHANH

Thành phố Hồ Chí Minh - Năm 2026

LỜI CAM ĐOAN

Tôi xin cam đoan đây là công trình nghiên cứu của riêng tôi. Các số liệu và kết quả nghiên cứu trong luận văn này là trung thực và chưa từng được công bố trong bất kỳ công trình nào khác. Những ý kiến khoa học, kết luận của luận văn hoàn toàn do tôi tự đúc kết trên cơ sở nghiên cứu và các tài liệu tham khảo đã được trích dẫn đầy đủ.

Luận văn này được hoàn thành dưới sự hướng dẫn khoa học của TS. Ngô Vũ Tấn Khanh. Tôi xin hoàn toàn chịu trách nhiệm trước Hội đồng và trước pháp luật về tính trung thực, khách quan cũng như mọi vấn đề liên quan đến bản quyền của luận văn này.

Thành phố Hồ Chí Minh, ngày tháng năm 2026

Tác giả

Nguyễn Hữu Tuấn

LỜI CẢM ƠN

Lời đầu tiên, tôi xin bày tỏ lòng biết ơn sâu sắc đến Thầy TS. Ngô Vũ Tấn Khanh, người đã luôn dành sự quan tâm, động viên và hướng dẫn tận tình, chu đáo cho tôi trong suốt thời gian thực hiện và hoàn thành đề án này. Những định hướng khoa học cùng những lời khuyên quý báu của Thầy chính là kim chỉ nam giúp tôi vượt qua nhiều thách thức để hoàn thiện nghiên cứu một cách tốt nhất.

Đồng thời, tôi cũng xin được gửi lời tri ân sâu sắc đến quý thầy, cô tại Trường Đại học Kinh tế Thành phố Hồ Chí Minh (UEH). Với tư cách là những người nhà giáo, quý thầy, cô đã truyền đạt cho tôi những nền tảng kiến thức chuyên môn sâu sắc và vững chắc trong suốt quá trình học tập tại trường. Chính những bài học và sự chỉ dạy tận tâm đó đã góp phần quan trọng giúp tôi định hình, tư duy và hoàn thành kết quả của đề án nghiên cứu này.

Cuối cùng, tôi xin chân thành cảm ơn gia đình, bạn bè và các đồng nghiệp đã luôn bên cạnh động viên, cổ vũ và tạo mọi điều kiện tốt nhất về cả vật chất lẫn tinh thần trong suốt chặng đường học tập và nghiên cứu vừa qua.

Dù đã có nhiều cố gắng, song đề án chắc chắn không tránh khỏi những thiếu sót nhất định. Tôi rất mong nhận được những ý kiến đóng góp, phê bình từ quý thầy, cô và Hội đồng để đề án được hoàn thiện hơn.

Tôi xin chân thành cảm ơn!

Thành phố Hồ Chí Minh, ngày tháng năm 2026

Tác giả

Nguyễn Hữu Tuấn

NHẬN XÉT CỦA NGƯỜI HƯỚNG DẪN

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

.....

Thành phố Hồ Chí Minh, ngày tháng năm 20...

Người hướng dẫn

[illegible]

☐ Duyệt thông qua

☐ Không thông qua

Ý kiến đề nghị:

.....

.....

.....

Hội đồng xét duyệt

MỤC LỤC

LỜI CAM ĐOAN

LỜI CẢM ƠN

MỤC LỤC

DANH MỤC CÁC TỪ VIẾT TẮT

DANH MỤC CÁC HÌNH

DANH MỤC CÁC BẢNG

TÓM TẮT - ABSTRACT

CHƯƠNG 1: XÁC ĐỊNH VẤN ĐỀ NGHIÊN CỨU

1.1	Tính cấp thiết của đề tài	1
1.2	Mục tiêu nghiên cứu	3
1.2.1	Mục tiêu chung	3
1.2.2	Mục tiêu cụ thể	4
1.2.3	Đối tượng nghiên cứu	5
1.2.4	Phạm vi nghiên cứu	6
1.3	Phương pháp nghiên cứu	6
1.4	Bố cục của đề án	8
1.5	Khoảng trống và động lực nghiên cứu	9

CHƯƠNG 2: LƯỢC KHẢO CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU

LIÊN QUAN 12

2.1	Tổng quan về bài toán phân tích sắc thái cảm xúc	12
-----	--	----

2.1.1	Cảm xúc và sắc thái tâm trạng qua lăng kính tâm lý học	12
2.1.2	Cơ sở thần kinh học của sự biểu hiện và hiện tượng suy hao cảm xúc trong văn bản	12
2.1.3	Bài toán phân tích sắc thái cảm xúc và các cấp độ phân tích . .	13
2.1.4	Phân tích sắc thái cảm xúc trên nền tảng học máy	15
2.1.5	Tổng quan về các thách thức phân tích sắc thái cảm xúc trên nền tảng YouTube	17
2.2	Tổng quan về phương pháp luận - Methodological Framework	19
2.3	Tổng quan về các mô hình dựa trên Transformer	21
2.4	Các nghiên cứu liên quan	24
2.4.1	Tình hình nghiên cứu ngoài nước	24
2.4.2	Tình hình nghiên cứu trong nước	25
2.5	Tổng hợp và nhận định nghiên cứu	27

CHƯƠNG 3: XÂY DỰNG KHUNG PHƯƠNG PHÁP 29

3.1	Tổng quan tiến trình thực hiện	29
3.2	Quy trình xây dựng và thu thập dữ liệu	30
3.3	Quy trình xử lý dữ liệu	33
3.4	Xây dựng quy trình gán nhãn bán tự động	35
3.5	Xây dựng mô hình Transformer	38
3.5.1	Xử lý mất cân bằng dữ liệu (Handling Imbalanced Data) . . .	38
3.5.2	Lựa chọn mô hình thực nghiệm	42
3.6	Các phương pháp đánh giá	42

CHƯƠNG 4: THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ NGHIÊN CỨU 44

4.1	Quy trình thực nghiệm	44
4.2	Kết quả thực nghiệm	45

4.2.1	Kết quả quá trình thu thập, xây dựng, tiền xử lý và gán nhãn dữ liệu	45
4.2.2	Kết quả quá trình huấn luyện mô hình	50
4.2.3	Kết quả quá trình kiểm thử mô hình	51
CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN		54
5.1	Kết luận chung	54
5.2	Hướng phát triển	55
DANH MỤC TÀI LIỆU THAM KHẢO		57

DANH MỤC CÁC TỪ VIẾT TẮT

NLP Natural Language Processing (Xử lý ngôn ngữ tự nhiên).

DANH MỤC CÁC HÌNH

1.1	Biểu đồ tỷ lệ thâm nhập của các nền tảng mạng xã hội dẫn đầu tại Việt Nam, từ Decision Lab, quý IV 2025	2
2.1	Khung phương pháp luận chung cho bài toán phân tích sắc thái cảm xúc.	21
2.2	Minh họa cơ chế tự chú ý (Self-Attention).	23
2.3	Kiến trúc tổng thể của Transformer với các lớp Encoder và Decoder. .	24
3.1	Sơ đồ minh họa quy trình tiền xử lý dữ liệu	33
3.2	Quy trình gán nhãn bán tự động	36
3.3	Phân phối dữ liệu theo đầu vào các nhóm cảm xúc: tích cực (xanh), tiêu cực (đỏ) và mập mờ (vàng).	39
3.4	Phân phối dữ liệu theo các nhóm cảm xúc sau khi giảm mẫu (Unsampling). Tích cực (xanh), tiêu cực (đỏ) và mập mờ (vàng).	39
4.1	Phân phối dữ liệu số lượng bình luận sau quá trình thu thập và tiền xử lý theo các danh mục.	46
4.2	Phân phối dữ liệu số lượng video sau quá trình thu thập và tiền xử lý theo các danh mục.	46
4.3	Biểu đồ violin phân phối số lượng từ trong từng bình luận.	47
4.4	Biểu đồ phân phối dữ liệu theo các nhóm cảm xúc (xanh - tích cực, đỏ - tiêu cực, vàng - nhập nhằng, xám - trung tính) sau khi được gán nhãn.	48
4.5	Biểu đồ phân phối dữ liệu theo các cảm xúc vi mô trong tập GoEmotions.	49
4.6	Biểu đồ hành vi trong quá trình hiệu chỉnh mô hình mBERT.	50
4.7	Quá trình hiệu chỉnh mô hình phoBERT.	50
4.8	Quá trình hiệu chỉnh mô hình mModernBERT.	51

DANH MỤC CÁC BẢNG

3.1	Các trường siêu dữ liệu cốt lõi của Video	32
3.2	Cấu trúc phân cấp các trường thông tin của Bình luận	32
3.3	Tổng hợp các độ đo đánh giá hiệu năng mô hình.	43
4.1	Cấu hình siêu tham số chi tiết cho từng mô hình thực nghiệm.	45
4.2	Kết quả đánh giá hiệu năng tổng thể của các mô hình trên tập kiểm thử.	51

TÓM TẮT

Trong bối cảnh YouTube sở hữu lượng người dùng khổng lồ tại Việt Nam, việc phân tích dữ liệu văn bản mang lại tiềm năng to lớn cho các bài toán trong lĩnh vực lắng nghe mạng xã hội. Tuy nhiên, quá trình xử lý ngôn ngữ tiếng Việt trên không gian mạng hiện đang đối mặt với nhiều thách thức do hiện tượng trộn mã (code-switching), sự đa dạng phương ngữ địa phương và biến đổi liên tục của ngôn ngữ mạng. Làm cho các phương pháp máy học truyền thống bộc lộ nhiều hạn chế khi xử lý loại dữ liệu phức tạp này, từ đó tạo động lực cho nghiên cứu nhằm ứng dụng các giải pháp học sâu hiện đại để cải thiện độ chính xác.

Mục tiêu của nghiên cứu này chính là xây dựng một khung phương pháp (framework) chuẩn dựa trên kiến trúc Transformer nhằm phân tích sắc thái cảm xúc của người dùng trên YouTube. Đề tài giải quyết bài toán nhận diện trạng thái tâm lý bằng cách bóc tách 27 trạng thái cảm xúc vi mô có độ hạt mịn cùng một trạng thái trung tính. Khoảng trống nghiên cứu chính là sự thiếu hụt các mô hình có khả năng phân loại cảm xúc chi tiết thay vì chỉ đánh giá phân cực tích cực hay tiêu cực cơ bản.

Nghiên cứu áp dụng phương pháp thực nghiệm định lượng kết hợp các kỹ thuật Xử lý ngôn ngữ tự nhiên tiên tiến. Quy trình thực hiện bao gồm việc thu thập dữ liệu, gán nhãn bán tự động có sự tham gia của Mô hình ngôn ngữ lớn và chuyên gia (LLM-Human-in-the-loop), hiệu chỉnh (fine-tuning) các mô hình ngôn ngữ như mBERT, PhoBERT, mModernBERT kết hợp các kỹ thuật xử lý mất cân bằng lớp.

Kết quả nghiên cứu cho thấy đề tài đã hoàn thiện thành công một chuỗi quy trình chuẩn hóa có khả năng nhận diện chính xác sự phức tạp trong tâm lý người dùng. Quá trình huấn luyện các mô hình đạt được hiệu năng cao, được đánh giá toàn diện qua các độ đo khách quan như F1-macro và Balanced Accuracy để phản ánh trung thực khả năng phân loại trên dữ liệu thực tế.

Kết quả nghiên cứu khẳng định khung phương pháp này có thể áp dụng làm nền

tăng kỹ thuật đặc lực cho các hệ thống Lắng nghe mạng xã hội (SociTrong bối cảnh YouTube sở hữu lượng người dùng khổng lồ tại Việt Nam, việc phân tích dữ liệu văn bản mang lại tiềm năng to lớn cho lĩnh vực lắng nghe mạng xã hội. Tuy nhiên, quá trình xử lý ngôn ngữ tiếng Việt trên không gian mạng hiện đang đối mặt với nhiều thách thức do hiện tượng trộn mã (code-switching), sự đa dạng phương ngữ và từ vựng biến đổi liên tục. Các phương pháp máy học truyền thống bộc lộ nhiều hạn chế khi xử lý loại dữ liệu phức tạp này, từ đó tạo động lực cho nghiên cứu nhằm ứng dụng các giải pháp học sâu hiện đại để cải thiện độ chính xác.

Từ khóa: *Phân tích cảm xúc, Transformer, YouTube, Tiếng Việt, Social Media Listening.*

ABSTRACT

In the context of YouTube possessing a massive user base in Vietnam, text data analysis offers immense potential for the field of social media listening. However, processing the Vietnamese language in cyberspace currently faces numerous challenges due to code-switching phenomena, dialectal diversity, and constantly evolving vocabulary. Traditional machine learning methods reveal many limitations when handling this complex data type, thereby creating the motivation for this research to apply modern deep learning solutions to improve accuracy.

The objective of this study is to develop a standardized methodological framework based on the Transformer architecture to analyze the emotional nuances of users on YouTube. The research addresses the problem of psychological state recognition by extracting 27 fine-grained micro-emotional states along with a neutral state. The main research gap lies in the lack of models capable of detailed emotion classification, rather than just basic positive or negative sentiment evaluation.

The study applies quantitative experimental methods combined with advanced Natural Language Processing techniques. The implementation process involves data collection, semi-automatic labeling with the participation of Large Language Models and experts (LLM-Human-in-the-loop), and fine-tuning language models such as mBERT, PhoBERT, and mModernBERT, combined with class imbalance processing techniques.

The research results show that the project has successfully developed a standardized pipeline capable of accurately recognizing the complexity of users' psychological states. The training process of the models achieved high performance, comprehensively evaluated through objective metrics such as F1-macro and Balanced Accuracy to truthfully reflect the classification capability on real-world data.

The findings confirm that this methodological framework can be effectively ap-

plied as a solid technical foundation for Social Media Listening systems in Vietnam. Businesses and content creators will directly benefit from understanding the community to optimize their business and development strategies. The implication for future research is to continue expanding the dataset and applying this architecture for analysis across various other social media platforms.


Keywords: *Sentiment analysis, Transformer, YouTube, Vietnamese, Social Media Listening.*

CHƯƠNG 1: XÁC ĐỊNH VẤN ĐỀ NGHIÊN CỨU

1.1 Tính cấp thiết của đề tài

Kể từ khi ra mắt vào năm 2005 và được chính thức bản địa hóa tại Việt Nam vào năm 2014, YouTube không chỉ dừng lại ở một mạng xã hội chia sẻ nội dung số, mà còn tạo ra một kho lưu trữ dữ liệu khổng lồ với giá trị khai thác lớn cho nhiều lĩnh vực. Dẫn chứng bởi nghiên cứu của Choudhury (2019), Việt Nam hiện là một trong năm thị trường trọng điểm và nhận được sự đầu tư tâm huyết nhất của YouTube trên thế giới. Tính đến cuối năm 2025, theo thống kê từ DataReportal (Kemp, 2026), YouTube sở hữu tệp người dùng lớn tại Việt Nam với 62,1 triệu tài khoản, tương đương 61% dân số cả nước. Đồng thời, báo cáo từ Decision Lab (Decision Lab, 2025) ghi nhận mức độ thâm nhập của nền tảng này lên tới 87% trong quý IV/2025 (Hình 1.1), chỉ xếp sau Facebook, Zalo và vượt qua TikTok. Những số liệu ấn tượng này minh chứng rằng hệ sinh thái YouTube đã mở ra tiềm năng to lớn cho các bài toán thuộc lĩnh vực lắng nghe mạng xã hội (Social Media Listening). Quy trình này được định nghĩa là việc ứng dụng các kỹ thuật khai phá dữ liệu nhằm theo dõi, giám sát và trích xuất tri thức hữu ích từ dòng chảy hội thoại xung quanh một thực thể cụ thể (như thương hiệu hoặc hashtag), từ đó hỗ trợ nhận diện cơ hội kinh doanh, tối ưu hóa chiến dịch marketing và nâng cao trải nghiệm khách hàng (Ducange *et al.*, 2019).

Trong bối cảnh hiện nay, sự phát triển đột phá của học máy (Machine Learning - ML) đã mở ra khả năng khai thác sâu sắc các nguồn dữ liệu phi cấu trúc, đặc biệt là văn bản, bên cạnh các dạng dữ liệu có cấu trúc truyền thống. Văn bản vốn là nguồn tài nguyên quan trọng chứa đựng các trạng thái nội tâm (private states) của con người, bao gồm ý kiến, niềm tin, suy nghĩ, tình cảm, cảm xúc, mục tiêu, đánh giá và phán đoán (Wiebe *et al.*, 2005). Như một hệ quả tất yếu, việc ứng dụng bài toán phân tích sắc thái cảm xúc (Sentiment Analysis - SA) để đánh giá tính phân cực trong văn bản đã trở thành giải pháp trọng tâm, giúp tối ưu hóa hoạt động khai phá dữ liệu trên mạng



Hình 1.1: Biểu đồ tỷ lệ thâm nhập của các nền tảng mạng xã hội dẫn đầu tại Việt Nam, từ Decision Lab, quý IV 2025

Nguồn: Decision Lab (2025)

xã hội.

Mặc dù nguồn dữ liệu công khai trên nền tảng YouTube vô cùng khổng lồ, phong phú, đa dạng và mang đặc tính đa miền (multi-domain), nhưng hướng tiếp cận hiện nay tại Việt Nam vẫn còn những khoảng trống nhất định. Trong khi bài toán phân tích sắc thái cảm xúc ở các ngôn ngữ phổ biến trên thế giới đã đạt được nhiều thành tựu đáng kể (Guo *et al.*, 2024; ZHAO *et al.*, 2024; Shen *et al.*, 2025; P. Zhao, 2025; Lee *et al.*, 2026), thì các nghiên cứu đối với tiếng Việt phần lớn vẫn chỉ tập trung vào các tập dữ liệu ngách thuộc một vài miền cụ thể (Minh *et al.*, 2024; Le *et al.*, 2025; D. X. Nguyen *et al.*, 2025).

Bên cạnh đó, dù nằm trong nhóm 20 ngôn ngữ có số lượng người bản ngữ lớn nhất thế giới (Ethnologue, 2026), tiếng Việt vẫn đặt ra nhiều thách thức đặc thù trong quá trình xử lý. Cụ thể, sự đa dạng của các phương ngữ và từ địa phương tạo ra rào cản không nhỏ đối với các mô hình xử lý ngôn ngữ tự nhiên (NLP). Đồng thời, sự giao thoa văn hóa trên không gian mạng đã thúc đẩy hiện tượng trộn mã (code-switching) (ví dụ: "sản phẩm nhìn rất chill") trở nên phổ biến và không ngừng biến đổi. Ngoài ra, sự thay đổi liên tục trong cách diễn đạt cảm xúc cùng sự xuất hiện của vốn từ vựng mới đòi hỏi các mô hình ML phải có tính thích nghi cao (adaptability) nhằm tránh hiện tượng suy giảm hiệu năng trước những biến động ngôn ngữ xã hội.

Trước những thách thức đặc thù này, các phương pháp truyền thống như hệ thống dựa trên luật (rule-based) hoặc các kiến trúc mạng học sâu thế hệ cũ (như Recurrent Neural Network - RNN hay Long Short-Term Memory - LSTM) dần bộc lộ nhiều điểm hạn chế do gặp khó khăn trong việc ghi nhớ ngữ cảnh dài và bóc tách cấu trúc câu trộn mã phức tạp. Trong bối cảnh đó, sự ra đời của kiến trúc Transformer dựa trên cơ chế tự chú ý (Self-Attention) do Vaswani *et al.* (2017) đề xuất đã tạo nên một bước ngoặt lớn trong lĩnh vực NLP. Nhờ tận dụng khả năng tính toán song song vượt trội, kiến trúc này cho phép nắm bắt toàn bộ ngữ cảnh trong văn bản một cách linh hoạt. Đây là yếu tố đặc biệt quan trọng giúp nâng cao độ chính xác khi giải quyết bài toán phân tích cảm xúc đa miền và tăng cường khả năng thích ứng của mô hình theo thời gian.

Xuất phát từ những yêu cầu thực tiễn cấp thiết nêu trên, câu hỏi đặt ra là làm thế nào để xây dựng một khung phương pháp (framework) chuẩn hóa, ứng dụng kiến trúc Transformer nhằm giải quyết hiệu quả các thách thức đặc thù của dữ liệu YouTube tại Việt Nam. Đây không chỉ là một bài toán có ý nghĩa về mặt học thuật mà còn mang tính ứng dụng thực tiễn cao, hỗ trợ đắc lực cho các nhà sáng tạo nội dung và doanh nghiệp trong việc thấu hiểu cộng đồng người dùng, từ đó đưa ra các chiến lược phát triển nội dung và kinh doanh tối ưu.

1.2 Mục tiêu nghiên cứu

1.2.1 Mục tiêu chung

Như đã phân tích ở trên, chúng ta thấy rằng việc nghiên cứu, thiết kế và đề xuất một khung phương pháp chuẩn (framework) dựa trên nền tảng kiến trúc Transformer là đòi hỏi cấp thiết đối với bài toán phân tích sắc thái cảm xúc của người dùng trên YouTube nói riêng và trên toàn bộ nền tảng mạng xã hội tại Việt Nam nói chung. Theo đó, mục đích cốt lõi của khung phương pháp này là tối ưu hóa toàn diện quy trình xây dựng và vận hành thực tế của hoạt động khai thác dữ liệu trên không gian mạng xã hội, trải dài từ khâu chuẩn bị dữ liệu, quy trình gán nhãn tự động cho đến khâu mô hình hóa theo đúng với xu thế thời đại.

Dựa trên lược đồ cảm xúc do Demszky *et al.* (2020) đề xuất trên cơ sở thực nghiệm của Cowen *et al.* (2019), nghiên cứu hướng tới việc bóc tách và làm rõ đặc tính phức tạp, đa chiều của trạng thái tâm lý con người thông qua hệ thống 27 phạm trù cảm xúc vi mô có độ hạt mịn (fine-grained). Hướng tiếp cận này vượt xa các mô hình phân loại sáu lớp cơ bản mà Ekman (1992) đặt ra hoặc các hệ thống đánh giá phân cực thô sơ truyền thống. Đặc biệt, thông qua việc cấu hình bài toán theo hướng phân loại đơn nhãn độc lập, nghiên cứu này không phủ nhận tính liên tục của không gian cảm xúc, mà thay vào đó là tập trung vào một cơ chế lọc tín hiệu tối ưu nhằm xác định chính xác tâm điểm cảm xúc chủ đạo (dominant emotion) chi phối mạnh nhất trong từng phát ngôn. Cách tiếp cận này vừa tận dụng trọn vẹn mật độ thông tin phong phú từ các khám phá tâm lý học hiện đại, vừa đảm bảo tính dứt khoát và rõ ràng cho các tác vụ ứng dụng thực tế ở hạ nguồn trên không gian mạng xã hội nói chung và nền tảng YouTube nói riêng.

1.2.2 Mục tiêu cụ thể

Để hiện thực hóa mục tiêu chung đã đề ra, nghiên cứu xác định và tập trung giải quyết bốn mục tiêu dựa trên các phần của một quy trình từ khâu thu thập dữ liệu cho tới mô hình hóa cụ thể như sau:

- Thu thập, xây dựng kho ngữ liệu bình luận (comments) cùng siêu dữ liệu (meta-data) xoay quanh các video trên nền tảng YouTube. Đồng thời, thiết lập một quy trình tiền xử lý văn bản nhằm bóc tách và chuẩn hóa các đặc trưng phi cấu trúc theo tiêu chuẩn huấn luyện hiện đại của các mô hình ngôn ngữ lớn. Nhằm xử lý các nhiễu loạn đặc thù của ngôn ngữ mạng, đảm bảo giữ lại trọn vẹn sắc thái ngữ nghĩa ẩn chứa trong từng ký tự và hành vi tương tác.
- Ứng dụng lược đồ 27 trạng thái cảm xúc và một trạng thái trung tính (neutral) mà Demszky *et al.* (2020) đã đề xuất, kết hợp với cơ chế gán nhãn bán tự động có sự tham gia của mô hình ngôn ngữ lớn và chuyên gia (LLM-Human-in-the-loop)

nhằm xác định chính xác tâm điểm cảm xúc chủ đạo (dominant emotion) trong từng văn bản một cách tối ưu và hợp với thời đại.

- Triển khai hiệu chỉnh (fine-tuning) mô hình dựa trên các kiến trúc Transformer đã được tiền huấn luyện chuyên biệt hoặc đa ngữ dành cho tiếng Việt (như mBERT, PhoBERT, mModernBERT). Đồng thời, áp dụng các kỹ thuật giải quyết vấn đề mất cân bằng phân lớp (class imbalance) mang tính đặc thù của dữ liệu thực tế. Cuối cùng, độ tin cậy và khả năng tổng quát hóa của khung phương pháp sẽ được kiểm chứng thông qua hệ thống các độ đo định lượng chuẩn mực.
- Dựa trên các kết quả đánh giá thực nghiệm, để hoàn thiện một chuỗi quy trình (pipeline) chuẩn hóa có khả năng nhận diện chính xác độ phức tạp trong trạng thái tâm lý người dùng. Khung phương pháp này đóng vai trò là nền tảng kỹ thuật hỗ trợ đắc lực cho các hệ thống lắng nghe mạng xã hội (Social Media Listening) tại Việt Nam. Tạo điều kiện cho các tác vụ hạ nguồn (downstream tasks) mang tính ứng dụng cao như phân tích xu hướng & đo lường sức khỏe thương hiệu hay quản trị danh tiếng thương hiệu & xử lý khủng hoảng truyền thông được thực thi một cách tự động, chính xác và có chiều sâu với một mức chi phí tối ưu.

1.2.3 Đối tượng nghiên cứu

- **Về mặt dữ liệu và ngôn ngữ học:** Đối tượng nghiên cứu là các trạng thái tâm lý, thái độ và biểu hiện cảm xúc đa chiều của người dùng Việt Nam được phản ánh qua ngữ liệu văn bản phi cấu trúc trên nền tảng mạng xã hội YouTube.
- **Về mặt công nghệ và thuật toán:** Đối tượng nghiên cứu tập trung vào các kiến trúc học sâu tiên tiến dựa trên cơ chế tự chú ý (Transformer-based models) chuyên biệt cho xử lý ngôn ngữ tự nhiên (NLP) đa ngữ và tiếng Việt. Bên cạnh đó, nghiên cứu cũng xem xét việc ứng dụng các Mô hình ngôn ngữ lớn (Large Language Models - LLMs) như một công cụ hỗ trợ quá trình phân tích và tự động hóa khâu gán nhãn dữ liệu.

1.2.4 Phạm vi nghiên cứu

- **Phạm vi dữ liệu:** Trong khuôn khổ đề án, việc thu thập và khai thác dữ liệu chỉ dừng lại ở việc giới hạn trong nền tảng YouTube tại thị trường Việt Nam. Nguồn dữ liệu đầu vào bao gồm các bình luận công khai từ các video phát lại (Video on Demand - VOD) và luồng phát trực tiếp (Livestream), kết hợp cùng các siêu dữ liệu (metadata) liên quan trực tiếp đến video như tiêu đề và mô tả.
- **Phạm vi phân loại cảm xúc:** Thay vì tiếp cận theo bài toán phân cực ba nhãn (tích cực, tiêu cực, trung tính) hoặc sáu cảm xúc phổ quát của Ekman (1992) đề xuất, phạm vi nhận diện của nghiên cứu được mở rộng sang không gian cảm xúc hạt mịn (fine-grained emotion categories). Cụ thể, đề án nghiên cứu áp dụng lược đồ 27 trạng thái cảm xúc vi mô kết hợp với một trạng thái trung tính (neutral) đã được Demszky *et al.* (2020) đề xuất, nhằm nắm bắt chính xác các sắc thái biểu đạt phức tạp và đa dạng của người dùng trong thực tế.
- **Phạm vi công nghệ áp dụng:** Trong quy trình gán nhãn có sự tham gia của chuyên gia (LLM-Human-in-the-loop), đề tài giới hạn việc thử nghiệm trên một số Mô hình ngôn ngữ lớn tiêu biểu hiện nay (như Gemini Flash, Llama 3, Gemma). Đối với khâu phân loại sắc thái cảm xúc, nghiên cứu tập trung thực nghiệm tinh chỉnh (fine-tuning) và đánh giá đối sánh (benchmarking) trên các kiến trúc Transformer đã được tiền huấn luyện (pre-trained) thuộc họ BERT (như mBERT, PhoBERT, mModernBERT).

1.3 Phương pháp nghiên cứu

Để giải quyết các mục tiêu đã đặt ra, đề án áp dụng phương pháp nghiên cứu thực nghiệm định lượng (quantitative empirical research) kết hợp với các kỹ thuật tiên tiến trong lĩnh vực Xử lý ngôn ngữ tự nhiên (NLP) và Học sâu (Deep Learning). Khung phương pháp này được định hình dựa trên việc tham khảo, kế thừa và tùy biến từ các quy trình phân tích cảm xúc từ hai công trình (Ding *et al.*, 2026; Hung *et al.*, 2026).

Từ những nền tảng lý thuyết và thực nghiệm vững chắc đó, đề án đã chuẩn hóa phương pháp triển khai thành một chuỗi quy trình (pipeline) bao gồm bốn giai đoạn trọng tâm như sau:

Bước 1: Chuẩn bị dữ liệu

- Bao gồm, không giới hạn công cụ cho việc xây dựng danh sách tập hạt giống video từ 15 chủ đề được YouTube chia sẵn.
- Cũng đồng thời, không giới hạn công cụ cho quá trình thu thập dữ liệu trên nền tảng YouTube như APIs, Web Scraping,... với nội dung bao gồm các thông tin về đối tượng bình luận (gồm nội dung bình luận, thời điểm bình luận) và các thông tin siêu dữ liệu (metadata) các thông tin về đối tượng video được bình luận (gồm tiêu đề, tên kênh, danh mục).
- Tham khảo và xây dựng quy trình tiền xử lý tập dữ liệu thô từ các quy trình chuẩn hiện đại trong những năm gần đây.

Bước 2: Gán nhãn bán tự động để xây dựng tập ngữ liệu lớn đã được gán nhãn

- Lấy mẫu, đánh nhãn thủ công và kết hợp với tập dữ liệu chuẩn (benchmark) Vi-GoEmotions do Hung *et al.* (2026) xây dựng để tạo tập hạt giống cho quá trình gán nhãn tự động.
- Chọn mô hình đã được huấn luyện trên tập ngữ liệu lớn, có độ chính xác cao để thực hiện việc gán nhãn tự động cho tập còn lại.
- Xây dựng một quy trình gán nhãn bán tự động dựa trên mô hình và tập hạt giống, nhằm mở rộng tập hạt giống, cũng chính là tập đã được gán nhãn chính xác.

Bước 3: Hiệu chỉnh mô hình

- Hiệu chỉnh mô hình với các kỹ thuật khử bất cân bằng dữ liệu với các mô hình được chọn để sử dụng cho giai đoạn mô hình hóa.
- Huấn luyện lại mô hình với kỹ thuật học chuyển giao (Transfer Learning) trên tập dữ liệu đã được gán nhãn ở giai đoạn trước. Nhằm tận dụng sức mạnh của mô hình ngôn ngữ lớn đã được huấn luyện trên các tập ngữ liệu đa dạng, giàu ngữ nghĩa cho việc học nhanh các đặc trưng của ngôn ngữ mạng xã hội phức tạp.

Bước 4: Đánh giá và so sánh kết quả

- Vì mục tiêu đề án là xây dựng một khung phương pháp để phù hợp với kiến trúc Transformer do đó, cần phải đánh giá quá trình huấn luyện của các mô hình ở bước 3 nhằm đưa ra kết luận chính xác mang tính trung thực khách quan.
- Vì dữ liệu vốn đã mang tính mất cân bằng trong tự nhiên, do đó chúng ta cần phải đánh giá thông qua các độ đo khách quan như F1-macro, Balanced Accuracy nhằm bổ sung cho độ đo độ chính xác tổng thể (Overall Accuracy).

1.4 Bố cục của đề án

Dựa trên khung phương pháp luận đã đề xuất, cùng các mục tiêu đã đặt ra, nội dung của luận văn được tổ chức thành 5 chương chính với bố cục như sau:

- **Chương 1: Xác định vấn đề nghiên cứu** - Giới thiệu bối cảnh nghiên cứu, tính cấp thiết của đề tài, xác định mục đích, mục tiêu, đối tượng và phạm vi nghiên cứu, cũng như phương pháp nghiên cứu và cung cấp cái nhìn sơ lược về bố cục của đề án.
- **Chương 2: Lược khảo cơ sở lý thuyết và các nghiên cứu trước** - Trình bày các khái niệm liên quan đến quá trình xây dựng khung phương pháp như khung phương pháp, bài toán phân tích sắc thái cảm xúc, kiến trúc Transformer, và các công trình nghiên cứu có liên quan đã được công bố trong và ngoài nước, nhằm cung cấp các định nghĩa tổng thể bài toán.

- **Chương 3: Phương pháp nghiên cứu** - Mô tả chi tiết quá trình xây dựng khung phương pháp từ quy trình thu thập dữ liệu, tiền xử lý, cho tới khâu mô hình hóa và đánh giá kết quả.
- **Chương 4: Kết quả nghiên cứu và thảo luận** - Mô tả chi tiết môi trường và các tham số cấu hình thực nghiệm. Tiến hành triển khai đánh giá đối sánh quá trình huấn luyện giữa các mô hình, phân tích định lượng dựa trên các độ đo tiêu chuẩn (Overall Accuracy, Balanced Accuracy, F1-macro) trên tập dữ liệu kiểm định để kiểm chứng hiệu năng thực tế của mô hình nhằm đưa ra các dữ liệu đánh giá khách quan về toàn bộ khung phương pháp.
- **Chương 5: Kết luận và hàm ý** - Tổng kết những đóng góp của nghiên cứu và đề xuất các hướng mở rộng.

1.5 Khoảng trống và động lực nghiên cứu

Như đã đề cập ở các phần trên, mặc dù lĩnh vực phân tích sắc thái cảm xúc (Sentiment Analysis) đã thu hút được nhiều sự quan tâm của giới nghiên cứu, nhưng khi soi chiếu vào bối cảnh thực tế phức tạp của nền tảng YouTube tại Việt Nam, mảng đề tài này vẫn tồn tại những khoảng trống đáng kể cả về mặt lý thuyết lẫn thực tiễn.

Thứ nhất, phần lớn các nghiên cứu trước đây về phân tích cảm xúc tiếng Việt chủ yếu tiếp cận ở mức độ phân cực thô sơ (tích cực, tiêu cực, trung tính) hoặc ứng dụng các mô hình học máy truyền thống và mạng học sâu thế hệ cũ như RNN hay LSTM. Tuy nhiên, chưa có nghiên cứu nào đề xuất và đánh giá hiệu quả của một khung phương pháp (framework) kết hợp Lược đồ 27 trạng thái cảm xúc vi mô và một cảm xúc trung tính với các kiến trúc Transformer tiên tiến (như PhoBERT, mModernBERT) cùng cơ chế gán nhãn LLM-Human-in-the-loop, nhằm tận dụng đồng thời cả hai ưu điểm: khả năng nhận diện cảm xúc hạt mịn (fine-grained) và năng lực bóc tách ngữ cảnh vượt trội của các mô hình ngôn ngữ hiện đại với lượng ngữ liệu lớn.

Thứ hai, một trong những thách thức lớn trong bài toán lắng nghe mạng xã hội là

sự nhiễu loạn và phức tạp của ngôn ngữ tự nhiên. Các nghiên cứu trước thường sử dụng dữ liệu đã được làm sạch một cách dứt khoát nhằm đánh đổi tính toàn vẹn của cảm xúc trên ngữ liệu với hiệu năng của mô hình. Hoặc là thu hẹp trong các miền cụ thể (như đánh giá nhà hàng, khách sạn, sản phẩm điện thoại). Trong khi đó, văn bản bình luận trên nền tảng YouTube thực tế mang tính đa miền (multi-domain), chứa nhiều hiện tượng trộn mã (code-switching), từ lóng, và đặc biệt là sự mất cân bằng phân lớp trầm trọng. Và việc xây dựng một quy trình tiền xử lý thực tiễn, bao gồm chuẩn hóa văn bản mạng, bóc tách đặc trưng mang tính hiện đại, phù hợp với các mô hình ngôn ngữ lớn và áp dụng các kỹ thuật khử bất cân bằng dữ liệu hợp lý là rất cần thiết, nhưng vẫn chưa được nghiên cứu kỹ lưỡng trong bối cảnh ứng dụng tại Việt Nam.

Thứ ba, nhiều nghiên cứu hiện nay vẫn tập trung đánh giá vào mô hình phân tích cảm xúc chủ yếu dựa trên độ chính xác tổng thể (Overall Accuracy), mà bỏ qua đánh giá quá trình huấn luyện giữa các mô hình. Điều này dẫn đến việc đánh giá toàn bộ quá trình xây dựng khung phương pháp từ khâu thu thập cho tới trực quan hóa vẫn chưa được toàn diện, đặc biệt trong bối cảnh ứng dụng thực tiễn của hệ thống lắng nghe mạng xã hội (Social Media Listening), nơi mà độ tin cậy của kết quả đầu ra phụ thuộc mật thiết vào tính xuyên suốt và sự liên kết chặt chẽ của từng mắt xích.

Về mặt tổng quan trong các mô hình xử lý ngôn ngữ tự nhiên hiện đại, kiến trúc Transformer nổi bật nhờ cơ chế tự chú ý (Self-Attention) giúp giải quyết triệt để hạn chế về bộ nhớ dài hạn, cho phép nắm bắt toàn bộ ngữ cảnh một cách linh hoạt (Vaswani *et al.*, 2017), trong khi các Mô hình ngôn ngữ lớn (LLMs) được biết đến với khả năng suy luận và hỗ trợ tự động hóa gán nhãn vượt trội. Mặc dù chưa có nhiều nghiên cứu chính thức tại Việt Nam áp dụng toàn diện sự kết hợp giữa hệ thống 27 + 1 nhãn cảm xúc vi mô và kiến trúc Transformer cho dữ liệu YouTube, nhưng trong các ngôn ngữ phổ biến trên thế giới, việc tích hợp này đã chứng minh được hiệu quả trong việc cải thiện độ chính xác và nắm bắt tâm lý phức tạp của người dùng. Do đó, nghiên cứu này kế thừa ý tưởng từ các thành tựu tiên tiến toàn cầu để đề xuất một chuỗi quy trình

(pipeline) chuẩn hóa, nhằm tận dụng đồng thời năng lực học chuyển giao của các mô hình họ BERT và hệ thống phân loại hạt mịn, qua đó nâng cao hiệu suất nhận diện cảm xúc trong điều kiện dữ liệu thực tế đầy nhiễu và biến thiên.

Trên cơ sở những khoảng trống nêu trên, đề tài "Khung phương pháp phân tích sắc thái cảm xúc của người dùng Việt Nam trên nền tảng YouTube dựa trên kiến trúc Transformer" không chỉ đóng góp về mặt học thuật thông qua việc đề xuất một quy trình kết hợp mới mẻ, mà còn có tiềm năng ứng dụng cao trong việc tối ưu hóa hệ thống lắng nghe mạng xã hội (Social Media Listening) cho các doanh nghiệp và nhà sáng tạo nội dung hiện nay.

CHƯƠNG 2: LƯỢC KHẢO CƠ SỞ LÝ THUYẾT VÀ CÁC NGHIÊN CỨU LIÊN QUAN

2.1 Tổng quan về bài toán phân tích sắc thái cảm xúc

2.1.1 Cảm xúc và sắc thái tâm trạng qua lăng kính tâm lý học

Trong cuộc sống hàng ngày, khái niệm cảm xúc (emotion) và sắc thái tâm trạng (sentiment) thường được dùng để thay thế lẫn nhau. Tuy nhiên, trong lĩnh vực tâm lý học, chúng được coi là hai khái niệm khác biệt. Trong mô hình tâm lý học nổi tiếng mà Watson and Tellegen (1985) xây dựng, đã chỉ ra cảm xúc mang cấu trúc hai chiều. Dựa trên đó, cảm xúc được định nghĩa là một trạng thái tâm lý cốt lõi phát sinh tức thời, bao gồm ba thành phần cấu trúc: trải nghiệm chủ quan, phản ứng sinh lý và phản ứng hành vi. Nhà tâm lý học Ekman (1992) đã phân loại cảm xúc thành sáu nhóm cơ bản (hạnh phúc, buồn bã, tức giận, sợ hãi, ngạc nhiên, ghê tởm), và sau này được mở rộng với các trạng thái thứ cấp như hào hứng, xấu hổ, khinh thường và thẹn thùng.

Ngược lại, sắc thái tâm trạng (sentiment) là một thái độ tinh thần mang tính tổ chức cao, được bồi đắp và hình thành dựa trên nền tảng của các cảm xúc sơ cấp. Định nghĩa này nhấn mạnh rằng "sentiment" được sử dụng để truyền tải những suy nghĩ của một cá nhân bắt nguồn từ chính cảm xúc của họ. Không giống như cảm xúc, "sentiment" tiến xa hơn một bước và không bị giới hạn trong các chiều không gian tâm lý thuần túy (Yue *et al.*, 2019). Theo McDougall (2015), sắc thái tâm trạng đóng vai trò như cầu nối giữa cảm xúc cốt lõi và chuỗi hành động có chủ đích. Nói cách khác, các loại cảm xúc đa dạng đóng vai trò như những nhân tố cấu thành nên sắc thái tâm trạng tổng thể của một cá nhân đối với một sự vật, sự việc.

2.1.2 Cơ sở thần kinh học của sự biểu hiện và hiện tượng suy hao cảm xúc trong văn bản

Dựa trên cơ sở lý thuyết của các nhà tâm lý học, các nhà khoa học thần kinh đã tiến sâu vào giải mã cơ chế sinh học của quá trình hình thành và truyền đạt cảm xúc.

Khi con người tiếp nhận một kích thích từ môi trường, tín hiệu ngay lập tức được truyền qua đồi thị (Thalamus) đến hạch hạnh nhân (Amygdala) - trung tâm xử lý cảm xúc cốt lõi, đồng thời truyền đến vỏ não trước trán (Prefrontal Cortex) để phân tích nhận thức (LeDoux, 2013). Sau đó, hệ thần kinh tự chủ (Autonomic Nervous System) phản ứng bằng cách thay đổi nhịp tim, nhịp thở, tạo ra các "cảm giác" về mặt thể chất. Kết quả của quá trình này là các hành vi biểu hiện cảm xúc ra bên ngoài thông qua nét mặt, cử chỉ hoặc ngôn ngữ.

Tuy nhiên, khi cảm xúc phức tạp này được mã hóa xuống cấp độ ngôn ngữ dưới dạng văn bản thuần túy, một lượng lớn thông tin bị triệt tiêu. Theo nguyên tắc giao tiếp nổi tiếng của Albert Mehrabian, từ ngữ (ngôn từ) chỉ chiếm khoảng 7% khả năng truyền tải ý nghĩa cảm xúc, phần còn lại phụ thuộc vào ngữ điệu giọng nói (38%) và ngôn ngữ cơ thể (55%) (Mehrabian *et al.*, 1971). Do đó, một văn bản chữ viết đã đánh mất đến 93% các manh mối cảm xúc phi ngôn ngữ.

Đối với người tiếp nhận, quá trình giải mã cảm xúc cũng sẽ đi qua một chu trình thần kinh phức tạp. Tín hiệu đầu vào (đọc văn bản, nghe âm thanh, nhìn nét mặt) được xử lý thông qua hệ thống nơ-ron gương (Mirror Neuron System) trong não bộ. Các nơ-ron này kích hoạt sự "mô phỏng" tự động, ra lệnh cho cơ thể tái hiện lại trạng thái cảm giác của người phát tín hiệu. Tín hiệu mô phỏng này sau đó được chuyển đến thùy đảo (Insula) và hạch hạnh nhân để não bộ có thể thực sự "cảm nhận", từ đó phân tích và ra quyết định phân loại sắc thái tâm trạng đó là tích cực, tiêu cực hay trung tính (Iacoboni, 2009).

2.1.3 Bài toán phân tích sắc thái cảm xúc và các cấp độ phân tích

Phân tích sắc thái cảm xúc (Sentiment Analysis - SA), hay còn được gọi là khai thác ý kiến (Opinion mining), là lĩnh vực nghiên cứu chuyên sâu về các quan điểm, thái độ và cảm xúc của con người được diễn đạt thông qua ngôn ngữ văn bản (B. Liu *et al.*, 2010). Về mặt kỹ thuật, tác vụ này không chỉ dừng lại ở việc nhận diện từ vựng mang tính cảm xúc, mà là một quy trình trích xuất và phân loại các thông tin mang

tính chủ quan nhằm xác định chính xác thái độ của người viết hướng tới một thực thể cụ thể (B. Liu *et al.*, 2010).

Trong bài toán phân tích sắc thái cảm xúc, thuật ngữ *đối tượng* (o) thường được dùng để chỉ thực thể mục tiêu mà người viết hướng tới, chẳng hạn như sản phẩm, dịch vụ, cá nhân hoặc tổ chức. Về mặt cấu trúc, một đối tượng o có thể được phân tách thành một hệ thống phân cấp bao gồm các thành phần (T) và các thuộc tính (A). Chẳng hạn, nếu xét đối tượng o là một "Video", các thành phần T có thể bao gồm "nội dung", "âm thanh", "diễn viên"; các thuộc tính A tương ứng có thể là "độ chân thực" hay "kỹ năng diễn xuất". Và trong đó, bản thân các thành phần này cũng có thể tiếp tục chia nhỏ thành các thành phần con T_1 như "phân cảnh", "thông điệp truyền tải", "lời thoại",... và các thuộc tính con A_1 như "độ hấp dẫn", "độ sâu sắc", "tính logic",...

Dựa trên định nghĩa này, đối tượng o có thể được biểu diễn dưới dạng một cấu trúc cây phân cấp $o : (T, A)$, trong đó gốc là chính đối tượng o , các nút trong là các thành phần và các lá đại diện cho các thuộc tính chi tiết. Mặc dù cảm xúc có thể được biểu đạt tại bất kỳ nút nào trên cây, nhưng việc khai thác trực tiếp trên cấu trúc này thường gặp khó khăn do độ phức tạp về mặt tính toán và xử lý ngôn ngữ tự nhiên.

Do vậy, để tối ưu hóa quá trình khai thác, cấu trúc cây thường được đơn giản hóa bằng phương pháp "làm phẳng" (flattening). Khi đó, tất cả các thành phần và thuộc tính được gọi chung bằng thuật ngữ **khía cạnh** (aspect) hoặc **đặc tính** (feature), ký hiệu là f . Dựa trên nền tảng này, một ý kiến (opinion) sẽ được mô hình hóa chính thức dưới dạng một *bộ năm thành phần* (quintuple) (o, f, so, h, t) , trong đó:

- o : Đối tượng mục tiêu biểu đạt cảm xúc hay ý kiến trong văn bản.
- f : Khía cạnh của đối tượng được đánh giá.
- so : Hướng cảm xúc (sentiment orientation), thường mang giá trị tích cực, tiêu cực hoặc trung tính.
- h : Chủ thể (holder) diễn đạt cảm xúc.

- t : Thời điểm cảm xúc được biểu đạt.

Và đối với một văn bản $d = \langle s_1, s_2, \dots, s_m \rangle$, trong đó s_i là các câu cấu thành, mục tiêu của việc phân tích cảm xúc được phân định rõ ràng qua ba cấp độ nghiên cứu chính:

- **Cấp độ văn bản (Document-level):** Xác định hướng cảm xúc tổng thể của toàn bộ văn bản d đối với đối tượng o , thường được biểu diễn bằng cặp (o, so) .
- **Cấp độ câu (Sentence-level):** Xác định cảm xúc của từng câu s_i đối với đối tượng o . Cấp độ này thường đi kèm với nhiệm vụ phân loại tính chủ quan (subjectivity classification) để phân tách câu chứa ý kiến và câu nêu sự thật.
- **Cấp độ khía cạnh (Aspect-level):** Xác định hướng cảm xúc đối với từng khía cạnh cụ thể f_j của đối tượng o được đề cập trong câu s_i , biểu diễn bằng bộ (s_i, f_j, so) . Đây là cấp độ chi tiết nhất, cho phép xử lý các văn bản chứa nhiều ý kiến phức tạp và trái ngược nhau.

2.1.4 Phân tích sắc thái cảm xúc trên nền tảng học máy

Như đã lập luận ở phần cơ sở thần kinh học, quá trình chuyển hóa cảm xúc thành văn bản thuần túy gây ra hiện tượng suy hao thông tin nghiêm trọng (lên đến 93% các manh mối phi ngôn ngữ). Khi con người đọc văn bản, hệ thống nơ-ron gương (Mirror Neuron System) trong não bộ phải hoạt động liên tục để "mô phỏng" và bù đắp lượng thông tin khuyết thiếu này. Tuy nhiên, đối với máy tính, các phương pháp phân tích văn bản truyền thống dựa trên luật (rule-based) hoặc từ điển (lexicon) hoàn toàn bất lực trong việc khôi phục các tín hiệu cảm xúc ẩn, bởi chúng chỉ phân tích bề mặt từ vựng mà bỏ qua ngữ cảnh và cấu trúc ngữ nghĩa sâu xa (B. Liu, 2012).

Để giải quyết thách thức này, các phương pháp tiếp cận dựa trên Học máy (Machine Learning) và Học sâu (Deep Learning) ra đời, đóng vai trò như một "hệ thống nơ-ron gương kỹ thuật số". Thay vì dựa vào các quy tắc cứng nhắc, các thuật toán học máy có khả năng tự động trích xuất các biểu diễn đặc trưng phi tuyến tính (non-linear

representations) từ các tập dữ liệu lớn. Thông qua việc phân tích tần suất xuất hiện, vị trí, và mối liên kết ngữ cảnh giữa các từ, hệ thống có thể học cách suy luận và dự đoán sắc thái tâm trạng một cách tự động và chính xác.

Sự phát triển của phân tích sắc thái cảm xúc trên nền tảng học máy cũng đồng hành và không thể tách rời với các giai đoạn chính trong lĩnh vực xử lý ngôn ngữ tự nhiên, bao gồm:

- **Học máy truyền thống (Traditional Machine Learning):** Các thuật toán như Support Vector Machine (SVM), Naive Bayes, hay Logistic Regression sử dụng các kỹ thuật trích xuất đặc trưng thủ công như Bag-of-Words (BoW) hoặc TF-IDF. Mặc dù mang lại hiệu quả cao hơn phương pháp từ điển, nhóm này vẫn gặp hạn chế lớn trong việc hiểu chuỗi ngữ cảnh dài và thứ tự từ vựng.
- **Học sâu (Deep Learning):** Sự ra đời của các Mạng nơ-ron nhân tạo (Artificial Neural Networks) như RNN, CNN, LSTM và đặc biệt là kiến trúc Transformer đã tạo ra bước đột phá. Các mô hình này có khả năng nhúng từ vựng vào một không gian véc-tơ đa chiều (Word Embeddings), giúp biểu diễn trọn vẹn mối quan hệ ngữ nghĩa tinh vi và tự động phân tách đối tượng o cùng khía cạnh f trong bộ năm thành phần (o, f, so, h, t) .

Về mặt định nghĩa toán học, quá trình phân tích sắc thái cảm xúc bằng học máy là việc xấp xỉ một hàm mục tiêu để ánh xạ từ không gian văn bản đầu vào sang không gian nhãn cảm xúc. Gọi $\mathcal{D} = \{d_1, d_2, \dots, d_n\}$ là tập hợp các văn bản (hoặc câu, bình luận) cần phân tích. Gọi $\mathcal{E}$ là không gian nhãn cảm xúc được định nghĩa trước (ví dụ: $\mathcal{E} = \{\text{Tích cực, Tiêu cực, Trung tính}\}$ đối với phân loại 3 cực).

Mục tiêu của mô hình học máy là tối ưu hóa hàm ánh xạ f sao cho sai số dự đoán trên tập dữ liệu thực tế là nhỏ nhất. Tùy thuộc vào yêu cầu của bài toán, hàm f có thể được định nghĩa theo hai dạng:

- **Phân loại đơn nhãn (Single-label Classification):** Mô hình dự đoán một nhãn

cảm xúc chủ đạo duy nhất cho mỗi văn bản:

$$f : \mathcal{D} \rightarrow \mathcal{E} \quad (2.1)$$

- **Phân loại đa nhãn (Multi-label):** Mô hình đưa ra một véc-tơ phân phối xác suất liên tục, thể hiện mức độ xuất hiện của toàn bộ các trạng thái trong không gian nhãn đối với văn bản đầu vào:

$$f : \mathcal{D} \rightarrow [0, 1]^{|\mathcal{E}|} \quad (2.2)$$

2.1.5 Tổng quan về các thách thức phân tích sắc thái cảm xúc trên nền tảng YouTube

Trong bối cảnh kỷ nguyên số, nền tảng YouTube do Google phát triển, không chỉ đơn thuần là một nền tảng chia sẻ video nội dung số mà đã phát triển thành một hệ sinh thái mạng xã hội đa phương tiện khổng lồ, nơi hành vi tương tác của người dùng mang tính tổng hợp cao. Mà trong đó, người dùng tiếp nhận các kích thích đa giác quan (hình ảnh chuyển động, âm thanh, ngữ điệu của chủ thể sáng tạo nội dung) và phản hồi bằng cách để lại các văn bản dưới mục bình luận (comments). Chính đặc thù tương tác này khiến dữ liệu bình luận trên YouTube trở thành một trong những dạng dữ liệu thách thức nhất đối với bài toán phân tích sắc thái cảm xúc, đặc biệt khi xử lý ngôn ngữ tiếng Việt. Và các thách thức cốt lõi này được phân tích dưới hai góc độ: đặc điểm phi cấu trúc của văn bản và sự giới hạn của không gian nhãn truyền thống.

Đặc điểm phi cấu trúc của ngôn ngữ mạng xã hội:

Văn bản bình luận trên YouTube mang tính khẩu ngữ hóa rất cao, được viết một cách tự phát và không tuân theo các quy tắc ngữ pháp chuẩn mực của tiếng Việt. Nhằm mục đích bù đắp cho sự sụt giảm thông tin, người dùng mạng xã hội có xu hướng phát triển các cấu trúc ngôn ngữ biến thể để khuếch đại hoặc cụ thể hóa cảm xúc của mình.

Hệ quả là đã tạo ra các rào cản kỹ thuật nghiêm trọng đối với các hệ thống xử lý ngôn ngữ tự nhiên truyền thống:

- Người dùng sử dụng dày đặc các icon (như 🤔, 🙄, ...) hoặc ký tự biểu cảm (như : D, : 3, ^^). Các biểu tượng này đôi khi đóng vai trò quyết định sắc thái câu, hoặc thậm chí được dùng để mỉa mai, làm đảo ngược hoàn toàn ngữ nghĩa của văn bản chữ viết đi kèm.
- Các từ ngữ bị cố ý biến đổi hình thái theo thói quen của người dùng mạng (ví dụ: "quá" thành "oá", "biết" thành "bít", "rồi" thành "gòi") hoặc viết tắt (như "vcl", "ko", "đc").
- Do xu hướng toàn cầu hóa, người dùng Việt Nam thường xuyên lồng ghép các từ mượn tiếng Anh hoặc các thuật ngữ viết tắt tiếng Anh (như "chill", "flop", "visual", "cringe") vào mạch văn tiếng Việt, gây khó khăn cho các mô hình ngôn ngữ chỉ được huấn luyện trên văn bản đơn ngữ thuần túy.
- Các hành vi kéo dài nguyên âm, viết loạn xạ hoặc viết hoa toàn bộ câu nhằm nhấn mạnh cảm xúc (ví dụ: "hayyyy toooooáaaaa") đã dẫn tới việc tạo ra các từ ngoài từ điển (Out-Of-Vocabulary - OOV), làm suy giảm nghiêm trọng hiệu suất của các bộ tách từ (tokenizers) truyền thống.

Sự giới hạn của không gian nhãn phân cực truyền thống đối với cảm xúc vi mô:

Bên cạnh các thách thức về mặt xử lý ngôn ngữ thô, việc ánh xạ dữ liệu YouTube vào không gian nhãn truyền thống $\mathcal{E} = \{\text{Tích cực, Tiêu cực, Trung tính}\}$ bộc lộ những giới hạn lớn về mặt thông tin, làm phẳng và triệt tiêu các chiều cảm xúc sâu sắc của người dùng.

Trong môi trường mạng xã hội phức tạp, một nhãn phân cực thô không đủ sức truyền tải bản chất hành vi. Ví dụ, hai bình luận cùng bị gán nhãn "Tiêu cực" dưới một

video tin tức có thể mang hai trạng thái tinh thần hoàn toàn biệt lập: một bình luận thể hiện sự *Tức giận (Anger)* đối với hành vi của nhân vật, trong khi bình luận khác lại thể hiện sự *Buồn bã, Cảm thông (Sadness/Sympathy)* đối với một số phận ngặt nghèo. Dưới góc độ thần kinh học và phân tích hành vi, hai trạng thái này kích hoạt các vùng vỏ não khác nhau và dẫn đến các hành động phản hồi hoàn toàn khác nhau của người dùng. Tương tự, một phản hồi "Tích cực" có thể là sự *Ngưỡng mộ (Admiration)* hướng về tài năng của người làm video, hoặc lại là sự *Thèm muốn (Craving)* đối với một video đánh giá âm thực.

Sự thiếu hụt một không gian nhãn có "độ mịn" cao (fine-grained emotions) khiến các hệ thống trí tuệ nhân tạo (AI) hiện tại chưa thể hiểu sâu sắc động lực hành vi tương tác của người dùng. Thách thức này đặt ra nhu cầu tất yếu về việc dịch chuyển bài toán từ phân tích sắc thái phân cực cơ bản sang phân loại cảm xúc tinh vi, dựa trên các mô hình tâm lý học mở rộng như mô hình phổ cảm xúc liên tục 27 chiều của Demszky *et al.* (2020) đề xuất. Việc kết hợp các chiều cảm xúc tinh vi này cùng một nhãn trung tính đại diện cho các bình luận rác hoặc câu hỏi thông tin thuần túy (**không gian nhãn 27+1**) chính là đích đến để giải quyết triệt để sự suy hao thông tin dữ liệu trên nền tảng YouTube.


2.2 Tổng quan về phương pháp luận - Methodological Framework

Mặc dù hiện nay giới học thuật chưa có một định nghĩa thống nhất hoàn toàn về **khung phương pháp luận (methodological framework)**, tuy nhiên, khái niệm này nhìn chung được thừa nhận là một hệ thống mang tính định hướng, dẫn dắt nhà nghiên cứu qua một chuỗi các bước có trình tự nhằm giải quyết một bài toán cụ thể. Về mặt ngữ nghĩa, **phương pháp luận (methodological)** bao hàm tập hợp các phương pháp và nguyên lý đặc thù trong một lĩnh vực chuyên sâu, trong khi **khung (framework)** đóng vai trò là cấu trúc định hình các quy tắc và tư tưởng nền tảng. Theo McMeekin *et al.* (2020), việc áp dụng khung phương pháp luận không chỉ củng cố tính nhất quán và chặt chẽ của quy trình nghiên cứu, mà còn chuẩn hóa các phương pháp tiếp cận,

qua đó tối ưu hóa độ tin cậy và giá trị khoa học của kết quả đạt được. Dựa trên các tiền đề đó, một khung phương pháp luận chất lượng cần đáp ứng các tiêu chí cốt lõi sau.

- **Tính hệ thống (Systematicity):** Các bước phải được sắp xếp theo trình tự logic, có sự liên kết chặt chẽ và nhất quán xuyên suốt quy trình.
- **Tính toàn diện (Comprehensiveness):** Bao quát toàn diện và đầy đủ các giai đoạn thiết yếu, từ khâu xác định cơ sở lý luận, thu thập dữ liệu cho đến khâu thực thi và đánh giá.
- **Tính linh hoạt (Flexibility):** Có khả năng tinh chỉnh và thích ứng với đa dạng bối cảnh nghiên cứu cũng như đặc thù của từng loại dữ liệu mà không làm phá vỡ cấu trúc tổng thể.
- **Tính khả thi và Thực chứng (Feasibility & Evidence-based):** Khung phải được kiến tạo dựa trên nền tảng dữ liệu thực tế, tri thức và kinh nghiệm của chuyên gia và đã được kiểm chứng về tính ứng dụng thực tiễn thông qua các nghiên cứu thử nghiệm (pilot studies).

Ứng dụng vào phạm vi của bài toán phân tích sắc thái cảm xúc (Sentiment Analysis), các nghiên cứu đương đại, bất kể được thực hiện trên tiếng Việt hay các ngôn ngữ khác, phần lớn đều hội tụ về một quy trình chuẩn hóa. Cụ thể, quy trình này bao gồm các giai đoạn có tính tuần tự, lần lượt là: thu thập dữ liệu, tiền xử lý, tách từ (tokenization), véc-tơ hóa (vectorization), huấn luyện mô hình học máy và cuối cùng là đánh giá hiệu năng của mô hình (El Azzouzy *et al.*, 2025; Singh and Tiwari, 2021). Cấu trúc hệ thống này cũng thể hiện sự tương đồng sâu sắc với khung phương pháp luận tổng quát do Uma Maheswari *et al.* (2024) đề xuất (như Hình 2.1).



Hình 2.1: Khung phương pháp luận chung cho bài toán phân tích sắc thái cảm xúc.
Nguồn: Uma Maheswari *et al.* (2024)

Ngoài ra, khi đi sâu khảo sát các công trình nghiên cứu chuyên biệt về phân tích cảm xúc trên văn bản tiếng Việt, có thể nhận thấy xu hướng chủ đạo hiện nay là tập trung tinh chỉnh kiến trúc của các mô hình học sâu nhằm tối đa hóa độ chính xác dự đoán tổng thể (overall accuracy) (Minh *et al.*, 2024; D. X. Nguyen *et al.*, 2025; Quoc Tran *et al.*, 2023). Tuy nhiên, hướng tiếp cận này vô hình trung dẫn đến việc đề cao quá mức các chỉ số đánh giá định lượng (như Accuracy, F1-score) trên các tập dữ liệu chuẩn (benchmark datasets), trong khi chưa đầu tư đúng mức cho việc thiết kế một khung phương pháp luận có tính ứng dụng cao. Hệ quả tất yếu là các mô hình dù đạt mức hiệu năng tối ưu trong môi trường thực nghiệm được kiểm soát, song lại bộc lộ rõ sự thiếu hụt về tính bền vững (robustness) và khả năng khái quát hóa (generalization) khi đối mặt với dữ liệu thực tế, đặc biệt là trong bối cảnh ngôn ngữ mạng xã hội có mức độ biến thiên liên tục, phi cấu trúc và chứa nhiều nhiễu như hệ sinh thái bình luận trên nền tảng YouTube.

2.3 Tổng quan về các mô hình dựa trên Transformer

Kiến trúc Transformer, được giới thiệu bởi Vaswani và các cộng sự Vaswani *et al.* (2017), đã tạo nên một bước ngoặt quan trọng trong lĩnh vực xử lý ngôn ngữ tự

nhien (NLP). Mà trọng tâm của kiến trúc này là cơ chế tự chú ý (Self-Attention) (Hình 2.2), cho phép mô hình tính toán mối quan hệ giữa các từ trong một chuỗi văn bản một cách hiệu quả, bất kể khoảng cách giữa chúng.

Về mặt kiến trúc, Transformer bao gồm hai thành phần cốt lõi, bộ mã hóa (Encoder) và bộ giải mã (Decoder) (Hình 2.3), được xếp chồng lên nhau thành nhiều lớp. Trong đó:


- **Bộ mã hóa:** Đảm nhận việc xử lý dữ liệu đầu vào để tạo ra các biểu diễn ngữ nghĩa (embeddings) đa chiều và phong phú.
- **Bộ giải mã:** Khai thác các biểu diễn này để sinh ra chuỗi đầu ra mục tiêu.

Đồng thời, cơ chế tự chú ý cũng đóng vai trò quyết định giúp mô hình tập trung vào các thành phần quan trọng trong văn bản, từ đó tối ưu hóa khả năng hiểu ngữ cảnh và các liên kết ngữ nghĩa phức tạp. Mà dựa trên nền tảng này, các nghiên cứu sau đó cũng đã phát triển thành các nhánh mô hình chủ đạo.

- **Họ mô hình chỉ có bộ mã hóa (Encoder-only):** Điển hình là BERT (Devlin *et al.*, 2019) và RoBERTa (Y. Liu *et al.*, 2019). Nhóm này tập trung vào việc trích xuất đặc trưng ngữ nghĩa sâu sắc, phục vụ các tác vụ như phân loại văn bản, trích xuất thông tin và phân tích cảm xúc.
- **Họ mô hình chỉ có bộ giải mã (Decoder-only):** Tiêu biểu là dòng GPT Radford *et al.*, 2018, được tối ưu hóa cho việc sinh văn bản tự nhiên, hỗ trợ hiệu quả các nhiệm vụ như trả lời câu hỏi, tóm tắt và sáng tạo nội dung.


Và hiện nay, hầu hết các nghiên cứu tiên tiến về phân tích sắc thái cảm xúc đều kế thừa sức mạnh từ các kiến trúc dựa trên Transformer nhằm tận dụng được cơ chế tự chú ý để nắm bắt các thông tin ngữ cảnh một cách tự động và tối ưu hiệu suất phân lớp. Điều này đặt ra một lời giải chung cho các bài toán phân tích sắc thái cảm xúc

trong nước lẫn quốc tế ((Minh *et al.*, 2024), (D. X. Nguyen *et al.*, 2025), (Quoc Tran *et al.*, 2023)).



Hình 2.2: Minh họa cơ chế tự chú ý (Self-Attention).

Nguồn: Được Benveniste (2024) minh họa, tham khảo từ cơ chế Self-Attention mà Vaswani *et al.* (2017) đề xuất.



Hình 2.3: Kiến trúc tổng thể của Transformer với các lớp Encoder và Decoder.
 Nguồn: Vaswani *et al.* (2017)

2.4 Các nghiên cứu liên quan

2.4.1 Tình hình nghiên cứu ngoài nước

Trên thế giới, bài toán phân tích sắc thái cảm xúc đối với các ngôn ngữ phổ biến đã đạt được rất nhiều thành tựu đáng kể. Phần lớn các nghiên cứu tiên tiến nhất hiện nay đều đã chuyển dịch sang việc áp dụng các mô hình học máy dựa trên kiến trúc Transformer để giải quyết hiệu quả các bài toán phân tích đa miền (multi-domain). Bên cạnh việc tối ưu độ chính xác của mô hình, các nghiên cứu quốc tế cũng đã đề xuất và áp dụng thành công các khung phương pháp luận hệ thống chuyên biệt để xử

lý dữ liệu mạng xã hội, bao gồm các bước chuẩn hóa từ việc trích xuất API, tiền xử lý văn bản nhiều cho đến trực quan hóa kết quả đầu ra.

Demszky *et al.* (2020) đã xây dựng tập dữ liệu quy mô lớn GoEmotions tiên phong trong việc phân lớp các loại cảm xúc vi mô, giúp cải thiện đáng kể khả năng nhận diện các cảm xúc phức tạp (fine-grained emotions) trong văn bản tiếng Anh, vượt trội hơn so với các phương pháp phân loại tích cực hay tiêu cực truyền thống.

Gan *et al.* (2023) đã đề xuất mô hình phân tích cảm xúc phổ quát (Universal Sentiment Analysis - USA), đồng thời đóng góp một tập dữ liệu phân loại văn bản cảm xúc và từ loại chuyên biệt dành cho tiếng Nhật.

Uma Maheswari *et al.* (2024) đã triển khai một hệ thống tổng hợp cảm xúc (Sentiment Synthesis) nhằm chuyển hóa các bình luận trên nền tảng YouTube thành những thông tin chi tiết mang tính chiến lược. Kết quả nghiên cứu chứng minh rằng việc áp dụng các thuật toán xử lý ngôn ngữ vào bình luận trực tuyến giúp các nhà sáng tạo nội dung và doanh nghiệp nắm bắt chính xác phản ứng của người xem.

P. Zhao (2025) đề xuất một khung học sâu có khả năng diễn giải và trực quan hóa (Interpretable and Visual Deep Learning Framework) nhằm giải quyết bài toán phân tích cảm xúc trong các tình huống dịch vụ đa miền (multi-domain) và chuyên biệt cho tiếng Hàn.

Ding *et al.* (2026) đã trình bày khung phương pháp SCOPE dựa trên kiến trúc Transformer để phân tích cảm xúc của công chúng Trung Quốc đối với các vấn đề xã hội, như chính sách trì hoãn nghỉ hưu. Nghiên cứu cũng trình bày cách tổ chức dữ liệu phân cấp và phương pháp gán nhãn tự động với lượng dữ liệu lớn.

2.4.2 Tình hình nghiên cứu trong nước

Tại Việt Nam, mặc dù tiếng Việt thuộc nhóm 20 ngôn ngữ có quy mô cộng đồng sử dụng lớn nhất thế giới, các nghiên cứu về phân tích cảm xúc hiện nay phần lớn vẫn chỉ tập trung vào các tập dữ liệu ngách thuộc một miền (domain) cụ thể. Trọng tâm của các công trình nghiên cứu chuyên biệt về văn bản tiếng Việt chủ yếu tập trung vào

việc cải tiến cấu trúc các mô hình học máy để tối ưu hóa các chỉ số định lượng (như Accuracy, F1-score) trên các bộ dữ liệu mẫu (benchmark datasets).

Lê (2021) đã triển khai thử nghiệm áp dụng các kỹ thuật làm giàu dữ liệu (data augmentation) kết hợp cùng kiến trúc PhoBERT Base trên đa dạng các lĩnh vực như giáo dục, dịch vụ lưu trú và thương mại điện tử. Và thực hiện đánh giá mô hình được đánh giá toàn diện qua 5 thang đo tiêu chuẩn (bao gồm Accuracy và các biến thể của F1-score).

Quoc Tran *et al.* (2023) đã đề xuất mô hình kết hợp PhoBERT-CNN để phát hiện ngôn từ kích động thù hận và xúc phạm (hate and offensive speech) trong tiếng Việt nhằm mở rộng bài toán sang việc nhận diện các nội dung tiêu cực trên không gian mạng. Điểm đặc biệt của công trình này là việc khai thác nguồn dữ liệu luồng (streaming data) trực tiếp từ các nền tảng mạng xã hội, giúp mô hình tối ưu hóa khả năng xử lý các văn bản mang tính cập nhật liên tục và chứa nhiều ngôn ngữ mạng phức tạp.

Minh *et al.* (2024) đã tập trung tinh chỉnh (fine-tuning) kiến trúc PhoBERT nhằm phục vụ bài toán phân tích sắc thái cảm xúc của người dùng đối với các bài đánh giá điện thoại bằng tiếng Việt nhằm chuyên biệt hóa trong lĩnh vực thương mại điện tử. Nghiên cứu đã chứng minh tính hiệu quả của mô hình ngôn ngữ tiền huấn luyện khi được tối ưu hóa cho một miền dữ liệu cụ thể, giúp các doanh nghiệp công nghệ khai thác sâu sắc phản hồi của khách hàng.

D. X. Nguyen *et al.* (2025) đã mở rộng phạm vi ứng dụng sang dữ liệu đa phương tiện thông qua trường hợp nghiên cứu về các video ẩm thực đường phố Việt Nam trên nền tảng YouTube. Bằng cách phân tích phản hồi và tương tác của người xem, nhóm tác giả đã cung cấp một góc nhìn thực tiễn về xu hướng hành vi, thị hiếu và sắc thái cảm xúc của cộng đồng trực tuyến đối với các nội dung văn hóa số.

Hung *et al.* (2026) gần đây nhất đã giới thiệu ViGoEmotions, một bộ dữ liệu chuẩn quy mô lớn dành cho bài toán nhận diện cảm xúc vi mô (fine-grained emotion detection) trên văn bản tiếng Việt. Công trình này không chỉ đóng góp một tài nguyên học

thuật giá trị cho cộng đồng nghiên cứu trong nước mà còn nâng cao năng lực xử lý bối cảnh ngữ nghĩa tinh tế, tạo tiền đề cho các hệ thống trí tuệ nhân tạo thấu hiểu tâm lý người dùng Việt sâu sắc hơn.

2.5 Tổng hợp và nhận định nghiên cứu

Dựa trên các phân tích về cơ sở lý thuyết và lược khảo các công trình nghiên cứu trong và ngoài nước, có thể rút ra một số nhận định tổng quan như sau:

Thứ nhất, như đã trình bày ở phần 2.1.2, ngôn từ ở dạng văn bản thuần túy chỉ giữ lại khoảng 7% lượng thông tin cảm xúc nguyên bản do sự vắng mặt hoàn toàn của các tín hiệu phi ngôn ngữ. Sự khuyết thiếu nghiêm trọng này đòi hỏi các hệ thống phân tích ngôn ngữ tự nhiên phải có khả năng suy luận ngữ cảnh cao và năng lực trích xuất các đặc trưng ngữ nghĩa tiềm ẩn một cách tinh vi. Trong bối cảnh đó, các mô hình học sâu dựa trên kiến trúc Transformer, đặc biệt là nhờ cơ chế tự chú ý (Self-Attention), đã và đang giải quyết rất hiệu quả rào cản này bằng cách tự động mô phỏng lại các liên kết cảm xúc phức tạp bị ẩn giấu trong câu.

Thứ hai, đặc thù của ngôn ngữ mạng xã hội nói riêng và ngôn ngữ nói chung luôn biến thiên và thay đổi không ngừng do sự phát triển và va chạm giữa các nền văn hóa, lối sống trong giao tiếp. Sự bất ổn định này đòi hỏi các mô hình phân tích phải có khả năng thích ứng cao với các từ vựng mới (OOV) và cấu trúc ngữ pháp dị thường. Đồng thời, nó đặt ra yêu cầu khắt khe về việc toàn bộ quá trình nghiên cứu, huấn luyện và triển khai mô hình phải được hệ thống hóa một cách chặt chẽ theo các tiêu chuẩn công nghệ hiện đại, nhằm tối ưu hóa vòng đời phát triển phần mềm, tiết kiệm tài nguyên máy tính và tối ưu chi phí vận hành thực tế.

Thứ ba, hiện đang tồn tại sự chênh lệch lớn về mức độ hoàn thiện của các hệ thống phân tích giữa trong và ngoài nước. Trên thế giới, các nền kinh tế phát triển đã và đang áp dụng thành công các hệ thống phân tích tự động quy mô lớn, được dẫn dắt bởi những khung phương pháp luận hoàn chỉnh. Trong khi đó, tại Việt Nam, dù tiếng Việt nằm trong top 20 ngôn ngữ có quy mô sử dụng lớn nhất toàn cầu, nhưng vẫn chưa

có những công trình nghiên cứu đủ mạnh mẽ để kiến tạo một khung phương pháp luận chung. Hầu hết các nghiên cứu trong nước hiện nay vẫn còn phân tán, chủ yếu xoay quanh việc tối ưu hóa chỉ số cho các tập dữ liệu ngách nhỏ lẻ, thiếu tính chuyên biệt hóa và chưa đủ độ mở để sẵn sàng triển khai thành các hệ thống ứng dụng thực tiễn.

Cuối cùng, phần lớn các nghiên cứu trong nước vẫn đang bị giới hạn ở các bài toán phân loại phân cực cơ bản, dẫn đến việc phân tích sắc thái cảm xúc ở mức độ vi mô (fine-grained emotions) chưa được khai thác và đa dạng hóa đúng mức.

Từ những nhận định trên, có thể thấy việc xây dựng một quy trình nghiên cứu, phát triển và triển khai tổng thể, lấy sức mạnh của kiến trúc Transformer làm cốt lõi, kết hợp với việc ánh xạ vào không gian nhãn cảm xúc vi mô (27+1), và được cô đọng một cách hệ thống thông qua một khung phương pháp luận (methodological framework) là một yêu cầu tất yếu. Đây không chỉ là giải pháp bù đắp cho những giới hạn của các nghiên cứu đi trước, mà còn là chìa khóa để giải quyết triệt để bài toán thấu hiểu tâm lý và hành vi người dùng trên các hệ sinh thái phức tạp như nền tảng YouTube.

CHƯƠNG 3: XÂY DỰNG KHUNG PHƯƠNG PHÁP

3.1 Tổng quan tiến trình thực hiện

Nghiên cứu nhằm hướng tới việc phát triển một khung phương pháp luận (methodological framework) toàn diện dựa trên kiến trúc Transformer, nhằm giải quyết bài toán phân tích sắc thái cảm xúc của người dùng Việt Nam trên nền tảng YouTube và ứng phó hiệu quả với các thách thức thực tiễn đặc thù của dữ liệu mạng xã hội.

Quá trình nghiên cứu được hệ thống hóa và cô đọng thành một quy trình chuẩn, bao gồm năm thành phần cốt lõi như sau:

- Giai đoạn khởi đầu tập trung vào việc trích xuất bình luận và siêu dữ liệu (meta-data) từ một danh sách các video thuộc đa dạng các danh mục (categories) do YouTube đề xuất đã được thu thập và chuẩn bị trước đó. Với mục tiêu trọng tâm là xây dựng một bộ ngữ liệu quy mô lớn, đa dạng và có tính đại diện cao, bao quát trên nhiều lĩnh vực nhằm đáp ứng yêu cầu phân tích đa miền (multi-domain).
- Dữ liệu thô được đưa qua một quy trình xử lý nghiêm ngặt bao gồm các bước: lọc thô, chuẩn hóa, loại bỏ trùng lặp và tiến hành lọc sâu. Quy trình này được thiết kế nhằm khử tối đa các nhiễu loạn đặc thù của ngôn ngữ mạng xã hội (như từ lặp, sự lẫn lộn giữa các loại ngôn ngữ khác nhau) nhằm đảm bảo cho dữ liệu được "sạch", đồng thời vẫn bảo toàn trọn vẹn cấu trúc ngữ nghĩa và các manh mối cảm xúc gốc của văn bản bình luận.
- Gán nhãn bán tự động bằng các mô hình ngôn ngữ lớn và thực hiện hậu kiểm ba lần. Nhằm đưa ra một phương án tự động gán nhãn đối với dữ liệu lớn, tiết kiệm chi phí và thời gian so với phương pháp gán nhãn thủ công.
- Ứng dụng kỹ thuật Học chuyển giao (Transfer Learning) và các kỹ thuật xử lý mất cân bằng dữ liệu để tinh chỉnh các mô hình ngôn ngữ tiên tiến thuộc dòng họ

BERT. Quá trình hiệu chỉnh được thực hiện nhằm giúp mô hình khắc phục rào cản mất cân bằng phân lớp (class imbalance), gia tăng khả năng thích ứng với sự biến động của ngôn ngữ trực tuyến và duy trì tính khái quát hóa (generalization) cao trong môi trường đa miền.

- Hiệu năng của các mô hình sau huấn luyện được đo lường định lượng thông qua các thang đo chuẩn. Việc phân tích đối chứng toàn diện kết quả dự đoán và biểu đồ huấn luyện không chỉ cung cấp cái nhìn tổng quan về hiệu quả của từng kiến trúc mạng, mà còn là minh chứng thực nghiệm vững chắc khẳng định khung phương pháp luận này đáp ứng đầy đủ các tiêu chí cốt lõi đã được trình bày tại phần 2.2

3.2 Quy trình xây dựng và thu thập dữ liệu

Hiện tại, các bộ ngữ liệu chuẩn (benchmark) dành cho bài toán phân tích sắc thái cảm xúc cho tiếng Việt thường gặp như ViLexNorm, với số lượng khoảng trên 10 ngàn cặp (câu - nhãn), UIT-VSMEC với số lượng khoảng 7 ngàn cặp, trong khi đó bộ ngữ liệu gần đây nhất ViGoEmotions được cho là lớn nhất cũng chỉ có số lượng cực kỳ hạn chế khoảng 21 ngàn cặp với 28 lớp cảm xúc, và được phân loại đa nhãn.

Khi đặt lên bàn cân đối chiếu với các kho ngữ liệu quốc tế như YouNiverse (Ribeiro and West, 2021) (hơn 8,6 tỷ lượt tương tác bình luận) hay Douban-Dushu (J. Zhao and Ji, 2018) (hơn 37 triệu mẫu đánh giá từ nền tảng đọc sách), quy mô dữ liệu tiếng Việt hiện tại bộc lộ rõ sự chênh lệch sâu sắc. Hơn nữa, để khai thác triệt để năng lực biểu diễn ngữ nghĩa của các kiến trúc học sâu tiên tiến như Transformer, tập dữ liệu đầu vào đòi hỏi sự đáp ứng khắt khe không chỉ về "lượng" mà còn về "chất". Sự to lớn của dữ liệu ở đây phải được định hình thông qua tính đa dạng trong cấu trúc từ vựng, khả năng bao quát đa miền (multi-domain) và sự phong phú trong các tầng lớp ngữ nghĩa biểu đạt.

Xuất phát từ thực tiễn đó, trong giai đoạn này, mục tiêu cốt lõi được đặt ra là thu thập hàng triệu dòng bình luận thô từ nền tảng YouTube. Nguồn dữ liệu quy mô lớn

này sẽ là tiền đề vững chắc để xây dựng một bộ ngữ liệu chuẩn không chỉ mang đầy đủ tính đa dạng, đa miền, mà còn phản ánh chân thực tính phức tạp và độ nhiễu của ngôn ngữ mạng xã hội Việt Nam. Qua đó, nghiên cứu kỳ vọng tạo ra một không gian dữ liệu đủ sâu rộng, đáp ứng trọn vẹn yêu cầu huấn luyện các mô hình phân tích cảm xúc vi mô có độ chính xác và tính thích ứng cao.

Để thực hiện điều đó, ta cần phải thực hiện hai bước.

Bước 1, xây dựng một danh sách hạt giống gồm danh sách các kênh phổ biến ở Việt Nam, trong tất cả các lĩnh vực mà YouTube định nghĩa đề xuất, cụ thể là, thông qua nền tảng thống kê mạng xã hội thứ ba nổi tiếng, *socialblade* (Social Blade LLC, 2026). Đồng thời áp dụng quy trình thuật toán ?? để mở rộng tập danh sách hạt giống.

Algorithm 1 Thuật toán mở rộng tập dữ liệu kênh hạt giống dựa trên đề xuất của YouTube

Require: $S_{channel}$: Tập hạt giống ban đầu (danh sách các kênh)

Ensure: $S_{channel}$: Tập danh sách kênh sau khi đã được mở rộng toàn diện

```

1:  $Q \leftarrow S_{channel}$  ▷ Khởi tạo hàng đợi  $Q$  chứa các kênh cần duyệt
2: while  $Q \neq \emptyset$  do ▷ Lặp cho tới khi duyệt hết danh sách kênh (hàng đợi rỗng)
3:    $i \leftarrow$  Lấy (Pop) một kênh từ đầu hàng đợi  $Q$ 
4:    $V_i \leftarrow$  Lấy danh sách các video thuộc kênh  $i$ 
5:   for each video  $j \in V_i$  do ▷ Duyệt từng video  $j$  của kênh  $i$ 
6:      $C_{rec} \leftarrow$  Lấy 3 kênh đề xuất mới từ YouTube liên quan đến video  $j$ 
7:     for each kênh  $c \in C_{rec}$  do
8:       if  $c \notin S_{channel}$  then ▷ Đảm bảo kênh đề xuất chưa từng có trong tập
        hạt giống
9:          $S_{channel} \leftarrow S_{channel} \cup \{c\}$  ▷ Bổ sung ngay vào tập hạt giống
10:        Đẩy (Push) kênh  $c$  vào cuối hàng đợi  $Q$  ▷ Để tiếp tục duyệt
        video của kênh này ở các lượt sau
11: return  $S_{channel}$ 

```

Bước 2, tiến hành duyệt toàn bộ các video của toàn bộ các kênh trong danh sách các đường dẫn hạt giống (URLs) nhằm thu thập siêu dữ liệu (metadata) của video và hệ thống các bình luận đi kèm. Để phục vụ bài toán phân tích sắc thái cảm xúc đa miền và quản lý hiệu quả cấu trúc dữ liệu mạng xã hội, các thông tin này được tổ chức

theo mô hình phân cấp (hierarchical structure) tương tự như phương pháp luận do Ding *et al.* (2026) đề xuất. Mô hình này giúp phân tách rõ ràng giữa thực thể video (nút cha) và các luồng thảo luận (nút con), đồng thời bảo toàn cấu trúc phản hồi nhiều cấp (nested replies) của người dùng.

Cấu trúc lưu trữ và các trường thông tin chi tiết của hệ thống dữ liệu này được định nghĩa cụ thể thông qua Bảng 3.1 và Bảng 3.2.

Bảng 3.1: Các trường siêu dữ liệu cốt lõi của Video


Tên trường	Kiểu dữ liệu	Mô tả chi tiết
video_id	Varchar (PK)	Mã định danh duy nhất của video do YouTube cấp.
title	Text	Tiêu đề chính thức của video.
category	Varchar	Tên danh mục nội dung (ví dụ: edu, music, news, ...).
channel	Varchar	Tên của kênh YouTube đăng tải video.
video_type	Varchar	Loại video (gồm: static, short, stream).

Bảng 3.2: Cấu trúc phân cấp các trường thông tin của Bình luận

Tên trường	Kiểu dữ liệu	Mô tả chi tiết
comment_id	Varchar (PK)	Mã định danh duy nhất của bình luận.
video_id	Varchar (FK)	Mã định danh của video chứa bình luận (khóa ngoại liên kết với Bảng 3.1).
parent_id	Varchar (FK)	Mã định danh của bình luận gốc (chỉ xuất hiện đối với các phản hồi, nhận giá trị NULL nếu là bình luận cấp 1).
comment	Text	Nội dung văn bản thô của bình luận do người dùng nhập.
created_at	Datetime	Mốc thời gian bình luận được khởi tạo.
is_reply	Boolean	Biến cờ xác định trạng thái: True nếu là bình luận con (phản hồi) và False nếu là bình luận gốc.

3.3 Quy trình xử lý dữ liệu

Vì dữ liệu bình luận trên YouTube thường chứa nhiều nhiễu, sai ngữ pháp, lạm dụng emoji, từ lóng và ký tự đặc biệt. Nếu không tiến hành xử lý mà trực tiếp đưa vào mô hình, thì kết quả đầu ra sẽ rất hỗn loạn. Đối với các phương pháp Machine Learning truyền thống, tiền xử lý thường tập trung vào việc chuẩn hóa triệt để (như loại bỏ stop words, lowercase toàn bộ, stemming) để giảm không gian đặc trưng. Tuy nhiên, với các mô hình ngôn ngữ lớn dựa trên kiến trúc Transformer (LLMs), các bước như loại bỏ stop words là không cần thiết vì mô hình dựa vào ngữ cảnh từ để bắt ý nghĩa. Thay vào đó, mục tiêu của tiền xử lý đối với Transformer là làm sạch nhiễu vô ích trong khi bảo toàn tối đa các tín hiệu ngôn ngữ mang cảm xúc (Ahmad *et al.*, 2025).



Hình 3.1: Sơ đồ minh họa quy trình tiền xử lý dữ liệu

Do đó, trong đề án này, chúng ta thực hiện quy trình tiền xử lý gồm các công việc như trong sơ đồ quy trình tiền xử lý dữ liệu (như Hình 3.1) và cụ thể như sau:

Lọc thô (Raw Filter). Là quá trình loại bỏ các bình luận ('comment') không mang giá trị phân tích cho ngôn ngữ đích. Như các bình luận được viết hoàn toàn bằng tiếng nước ngoài (gồm các từ không thuộc họ latin như tiếng Nhật, tiếng Trung, tiếng Hàn,... và các họ thuộc Latin nhưng không phải tiếng Việt như tiếng Anh, tiếng Pháp, tiếng Bồ Đào Nha,...). Để thực hiện điều này chúng ta dùng thực hiện hai bước trong sơ đồ (như Hình 3.1).

Chuẩn hóa dữ liệu (Normalization). Là quá trình được thực hiện theo cơ chế "Top-Down" với 3 cấp độ như sau:

- **Cấp độ bình luận (Comment Document Level)**, ở cấp độ này ta thực hiện các điều chỉnh tập trung vào tính toàn vẹn và nhất quán ở toàn bộ một bình luận ('comment' hay 'document'). Mà cụ thể chúng ta sẽ thực hiện như sau.

- **Đồng nhất toàn bộ mã ký tự về chuẩn NFKC.**

- Mã hóa các thông tin nhận dạng hoặc vô nghĩa về mặt cảm xúc (URL, Email, Số điện thoại, Username, dãy số dài) thành các Token đặc biệt (ví dụ: [URL], [USER]).

- Giảm nhiều icon, rút gọn các chuỗi icon lặp lại liên tiếp (chỉ giữ tối đa 2 icon đại diện) và xóa bỏ sự lặp lại giữa các cụm icon.

- **Cấp độ câu (Sentence Level)**, ở cấp độ này mục tiêu chính là chuẩn hóa cấu trúc phân đoạn và các dấu hiệu kết thúc câu để tạo ra một văn bản mạch lạc. Cụ thể:

- Loại bỏ các khoảng trắng thừa quanh dấu xuống dòng và hợp nhất các dòng trống liên tiếp. Đối với các câu đã kết thúc bằng dấu câu (. ! ?) nhưng lại bị ngắt dòng, buộc ta phải thực hiện nối dòng để giữ tính liên tục của bình luận.

- Tiết chế các dấu câu lặp lại. Thông thường người dùng thường bình luận bằng các dấu câu lặp lại nhiều lần như !!!!!, ??????, để bày tỏ cảm xúc mạnh. Tuy nhiên nếu để như vậy mà đem vào mô hình học máy thì sẽ tốn nhiều tài nguyên. Nhưng xóa đi thì mất đi cường độ cảm xúc của bình luận, do đó ta chỉ giữ lại tối đa là 3 ký tự lặp lại cho các trường hợp như vậy.

- **Cấp độ từ (Word Level)**, đây là cấp độ xử lý sâu nhất, tập trung vào việc tinh chỉnh cấu trúc nội tại của từng từ và các cụm ký tự đặc biệt nhằm giảm thiểu sự bùng nổ của bộ từ vựng (vocabulary explosion). Và các công việc có thể gồm:

- Chuẩn hóa các cặp ngoặc.
- Xử lý kéo dài ký tự (Elongation Removal). Cũng tương tự như các dấu câu lặp lại, người dùng thường có xu hướng gõ nhiều lần một ký tự để thể hiện cảm xúc mạnh, do đó cách làm cũng tương tự chỉ giữ ở mức tối đa là 3 ký tự lặp lại. Đồng thời, các ký tự đặc biệt như =, <, >, ... vốn dùng để vẽ các emoji dưới dạng text, nhưng quá nhiều ký hiệu sẽ gây lãng phí tài nguyên, do đó chúng ta cũng giới hạn chúng ở mức tối đa là 2 hoặc 3 tùy loại.
- Khử lặp cụm ký hiệu, xử lý các trường hợp lặp lại từ hoặc cụm ký tự theo chu kỳ (ví dụ: "hahahaha", "hihihihi") bằng cách đưa chúng về một độ dài tiêu chuẩn, nhằm đồng nhất các biến thể khác nhau của cùng một biểu đạt cảm xúc.

Lọc bỏ các bình luận trùng lặp (Deduplication). Là quá trình loại bỏ các điểm dữ liệu bị lặp lại hoặc spam trong cùng một video theo từng khung thời gian (năm). Thuật toán MinHash (Broder *et al.*, 1998) được áp dụng để tính toán và lọc bỏ các bình luận có độ tương đồng ngữ nghĩa (Jaccard similarity) ở mức cao.


Lọc theo quy tắc (Heuristic Filtering). Là quá trình loại bỏ các bình luận theo các quy tắc cụ thể, chẳng hạn như lọc số lượng từ trong khoảng IQR, nhằm loại bỏ các outlier.

3.4 Xây dựng quy trình gán nhãn bán tự động

Mặc dù dữ liệu đã được chuẩn hóa và loại bỏ nhiều trong khi vẫn bảo toàn được phần lớn thông tin, bước gán nhãn dữ liệu (data labeling) vẫn là một yêu cầu bắt buộc. Theo các phương pháp truyền thống, quá trình này đòi hỏi sự tham gia độc lập của ít nhất ba chuyên gia để đảm bảo tính khách quan và độ tin cậy. Tuy nhiên, cách tiếp cận này tiêu tốn nhiều thời gian, chi phí và khó có thể mở rộng cho các tập ngữ liệu quy mô lớn lên đến hàng triệu mẫu.

Do đó, việc phát triển một quy trình gán nhãn bán tự động (semi-automated label-

ing) kết hợp giữa con người và máy tính là một yêu cầu cấp thiết. Cùng với sự phát triển mạnh mẽ của các Mô hình Ngôn ngữ Lớn (LLMs), phương pháp này đã được nhiều công trình nghiên cứu áp dụng như một quy trình chuẩn (Hung *et al.*, 2026; Ding *et al.*, 2026; Y. Wang *et al.*, 2023; Ratner *et al.*, 2017).



Hình 3.2: Quy trình gán nhãn bán tự động

Dựa trên phương pháp tiếp cận của Ding *et al.* (2026), quy trình gán nhãn bán tự động trong nghiên cứu này được thực hiện theo sơ đồ minh họa tại Hình 3.2. Quá trình này được triển khai theo các bước sau:

Xây dựng tập hạt giống và cân bằng dữ liệu.

Ban đầu, một tập dữ liệu hạt giống (seed dataset) gồm 10.000 mẫu được trích xuất ngẫu nhiên từ tập dữ liệu đã qua tiền xử lý. Để giải quyết vấn đề mất cân bằng dữ liệu đối với các nhãn hiếm (ví dụ: *grief*, *nervousness*, *remorse*, ...), phương pháp trích xuất dựa trên tập luật từ vựng (rule-based) được tích hợp nhằm thu thập thêm mẫu. Cụ thể:

- Các văn bản chứa những từ khóa như "*chia buồn*", "*xót xa*", "*mất mát*", "*vĩnh biệt*" hoặc "*rip*" có xác suất cao thuộc nhãn *grief*.

- Các từ khóa "*xin lỗi*", "*hối hận*", "*cấn rứt*" được sử dụng để lọc các mẫu có khả năng thuộc nhãn remorse.

Kế tiếp, tập hạt giống được bổ sung thêm dữ liệu từ bộ ngữ liệu **ViGoEmotions** nhằm gia tăng sự đa dạng về cả số lượng lẫn chất lượng. Hơn nữa, do sự chênh lệch tỷ lệ phân bố lớn (khoảng 1:30) giữa các nhãn hiếm và nhãn phổ biến, kỹ thuật sinh dữ liệu nhân tạo (synthetic data generation) thông qua các mô hình LLMs (như Gemini, GPT, ...) cũng được áp dụng để làm phong phú thêm tập huấn luyện.

Lựa chọn mô hình huấn luyện.

Sau khi xây dựng thành công tập hạt giống, một mô hình ngôn ngữ dựa trên kiến trúc Encoder – cụ thể là ViSoBert (N. Nguyen *et al.*, 2023), mô hình đã được huấn luyện trước (pre-trained) trên ngữ liệu mạng xã hội tiếng Việt – được lựa chọn để thực hiện nhiệm vụ phân loại.

Vòng lặp gán nhãn giả (Iterative Pseudo-labeling)

Quy trình lặp (iteration) của hệ thống gán nhãn bắt đầu bằng việc tinh chỉnh (fine-tuning) mô hình trên tập hạt giống nhằm tối ưu hóa hiệu suất (hướng tới việc cực đại hóa chỉ số F1-macro). Sau đó, mô hình đã qua tinh chỉnh được sử dụng để dự đoán (gán nhãn giả - pseudo labeling) cho toàn bộ phần dữ liệu chưa gán nhãn còn lại.

Dựa trên kết quả dự đoán, các mẫu dữ liệu mới được trích xuất để cập nhật vào tập huấn luyện cho vòng lặp tiếp theo bằng chiến lược chọn mẫu động:

- **Giai đoạn đầu (khi tập mới < 100.000 mẫu hoặc phân bố nhãn chưa đồng đều):** Thuật toán sẽ trích xuất K_{SAMPLE} mẫu có độ tin cậy dự đoán (prediction probability) cao nhất cho mỗi nhãn để đưa vào tập huấn luyện mới.
- **Giai đoạn sau (khi tập huấn luyện đã đạt kích thước đủ lớn):** Quy trình tiếp tục bằng việc chỉ trích xuất những mẫu có xác suất dự đoán vượt qua một ngưỡng tin cậy cố định (ví dụ: > 0.85 hoặc > 0.9).


3.5 Xây dựng mô hình Transformer

Nhằm đưa ra lời khẳng định về tính khả thi của khung phương pháp (framework) trên cơ sở minh chứng thực nghiệm định lượng khách quan, và chứng minh sự cân bằng tối ưu giữa *hiệu năng phân lớp (classification performance) tổng thể* và *độ nhạy của mô hình đối với các nhóm dữ liệu thiểu số (vốn chiếm tỷ trọng nhỏ nhưng mang sắc thái cảm xúc cao)*. Đồng thời, minh chứng cho tính thực tiễn và độ tương thích của khung phương pháp được đề xuất với các kiến trúc Transformer hiện đại, quy trình thực nghiệm sẽ trải qua quá trình tiến hành tinh chỉnh (fine-tuning) các mô hình mang tính đại diện trên tập dữ liệu thu được từ các giai đoạn trước thu thập, tiền xử lý và gán nhãn trước đó. Bước này nhằm đánh giá khả năng thích ứng linh hoạt và tối ưu của các mô hình đối với ngữ liệu thực tế.


Trước khi tiến hành huấn luyện và tinh chỉnh mô hình, bước phân tích khám phá dữ liệu (Exploratory Data Analysis) được thực hiện trên tập ngữ liệu thu được. Như đã trình bày ở các phần trước, do xu hướng tâm lý tự nhiên ít bộc lộ cảm xúc tiêu cực một cách trực diện, phân phối dữ liệu thực tế thường mất cân bằng nghiêm trọng. Dữ liệu có xu hướng lệch hẳn về các nhãn tích cực và trung tính, trong khi các nhãn tiêu cực xuất hiện với tần suất rất thấp (được minh họa tại Hình 3.3). Do đó, tập dữ liệu cần được xử lý thông qua kỹ thuật giảm mẫu đa số (Undersampling) trước khi đưa vào quá trình huấn luyện. Tuy nhiên, vì sự chênh lệch này phản ánh đúng thiên kiến thực tế trong giao tiếp của con người, mục tiêu của kỹ thuật giảm mẫu không nhằm cân bằng tuyệt đối tỷ lệ các lớp, mà chỉ tập trung vào việc điều chỉnh chênh lệch số lượng mẫu về một ngưỡng có thể chấp nhận được. Điều này giúp mô hình có khả năng học các đặc trưng của nhãn thiểu số mà không làm biến dạng hoàn toàn phân phối tự nhiên của dữ liệu (được minh họa tại Hình 3.4).

3.5.1 Xử lý mất cân bằng dữ liệu (Handling Imbalanced Data)

Vì vẫn tồn tại sự mất cân bằng đáng kể giữa các nhóm cảm xúc tích cực và tiêu cực. Đặc biệt, các nhãn cảm xúc vi mô hiếm gặp (như sợ hãi - fear, lo lắng - nervousness,



Hình 3.3: Phân phối dữ liệu theo đầu vào các nhóm cảm xúc: tích cực (xanh), tiêu cực (đỏ) và mập mờ (vàng).



Hình 3.4: Phân phối dữ liệu theo các nhóm cảm xúc sau khi giảm mẫu (Unsampling). Tích cực (xanh), tiêu cực (đỏ) và mập mờ (vàng).

thương tiếc - grief, ...) chiếm tỷ trọng rất nhỏ. Do đó, việc huấn luyện hoặc tinh chỉnh mô hình trực tiếp trên tập dữ liệu này mà không có biện pháp can thiệp sẽ dẫn đến hiệu suất thấp. Mô hình dễ rơi vào trạng thái cực đoan, khái quát hóa quá mức trên các nhãn đa số (tích cực) và bỏ qua các nhãn thiểu số (tiêu cực).

Để giải quyết vấn đề này, quá trình mô hình hóa cần phải áp dụng kết hợp phương pháp **Class-Balanced Loss (CB-Loss)** do Cui *et al.* (2019) đề xuất và **Gradient Harmonized Mechanism Loss (GHM-Loss)** do Li *et al.* (2019) đề xuất nhằm điều chuẩn (regularize) quá trình huấn luyện. Nhờ có sự tận dụng khả năng định hướng trọng số theo phân phối lớp của CB-Loss và khả năng điều tiết dựa trên độ khó thực tế của từng mẫu dữ liệu từ GHM-Loss. Sự cộng hưởng này sẽ giúp mô hình không bị áp đảo bởi các lớp có số lượng mẫu lớn, đồng thời tránh được hiện tượng quá khớp (overfitting) vào các mẫu nhiễu (outliers). Cụ thể, cơ sở toán học của phương pháp được biểu diễn như sau:

Giả sử một mẫu dữ liệu có nhãn thực (true label) là $y \in \{1, 2, \dots, C\}$ (với C là số lượng nhãn) và xác suất dự đoán của mô hình cho lớp y là p_y . Gọi g là độ lớn gradient của mẫu dữ liệu đối với đầu ra của mô hình, được định nghĩa bằng $g = |p_y - 1|$.

Class-Balanced Loss được thiết kế để giải quyết bài toán mất cân bằng dữ liệu bằng cách sử dụng khái niệm *số lượng mẫu hiệu dụng (effective number of samples)* nhằm tính toán trọng số cân bằng cho một lớp cụ thể y :

$$W_y = \frac{1 - \beta}{1 - \beta^{n_y}}$$

Trong đó:

- n_y là số lượng mẫu của lớp y trong toàn bộ tập dữ liệu huấn luyện.
- $\beta \in [0, 1)$ là một siêu tham số điều chỉnh (thông thường $\beta = 0.99$ hoặc 0.999).

Khi đó, hàm mất mát CB-Loss áp dụng trên hàm **Cross-Entropy (CE)** tiêu chuẩn có dạng:

$$\mathcal{L}_{\text{CB}}(p_y) = -\frac{1-\beta}{1-\beta^{n_y}} \log(p_y)$$

Gradient Harmonized Mechanism Loss (GHM-Loss) được đề xuất nhằm điều chỉnh trọng số của mẫu dựa trên Mật độ Gradient (Gradient Density), giúp giảm thiểu ảnh hưởng của các mẫu quá dễ dự đoán hoặc các mẫu nhiễu cực khó. Hàm mật độ gradient của một giá trị g được xác định bằng:

$$GD(g) = \frac{1}{R_i} \sum_{k=1}^N \delta(g_k, g)$$

Trong đó:

- N là tổng số mẫu trong một batch huấn luyện (training batch). g_k là độ lớn gradient của mẫu thứ k .
- $\delta(g_k, g)$ là hàm chỉ dấu, có giá trị bằng 1 nếu g_k nằm trong khoảng (bin) của g và bằng 0 trong trường hợp ngược lại.
- R_i là độ rộng của khoảng chứa g .

Với hệ số điều hòa GHM được tính bằng nghịch đảo của mật độ $\hat{\beta}_i = \frac{N}{GD(g)}$, hàm mất mát GHM-Loss được định nghĩa như sau:

$$\mathcal{L}_{\text{GHM}} = \frac{1}{N} \sum_{i=1}^N \frac{-\log(p_{y,i})}{GD(g_i)}$$

Để đồng thời tối ưu hóa cả hai khía cạnh — cân bằng số lượng mẫu hiệu dụng giữa các lớp và điều hòa độ khó của từng mẫu riêng lẻ — hàm mất mát hỗn hợp (Mixture Loss) được triển khai như sau:

$$\mathcal{L}_{\text{Mixture}} = W_y \cdot \mathcal{L}_{\text{GHM}}$$

3.5.2 Lựa chọn mô hình thực nghiệm

Do khung phương pháp được thiết kế tập trung vào các kiến trúc Transformer dạng Encoder, quy trình thực nghiệm giới hạn đánh giá trên các mô hình thuộc họ BERT. Dựa trên tiến trình phát triển của công nghệ xử lý ngôn ngữ tự nhiên, ba mô hình đại diện được lựa chọn bao gồm:

- **mBERT** (Devlin *et al.*, 2019): Được phát hành bởi Google cùng thời điểm với BERT. Đây là một trong những mô hình tiên phong của kỷ nguyên tiền huấn luyện đa ngôn ngữ, được huấn luyện đồng thời trên ngữ liệu Wikipedia của 104 ngôn ngữ khác nhau (bao gồm cả tiếng Việt).
- **PhoBERT** (D. Q. Nguyen and A.-T. Nguyen, 2020): Mô hình đơn ngôn ngữ (Monolingual) dựa trên kiến trúc RoBERTa, được huấn luyện hoàn toàn bằng một kho ngữ liệu tiếng Việt quy mô lớn (30GB văn bản thô từ báo chí, văn học và mạng xã hội). Nhờ chiến lược phân mảnh từ (word segmentation) ở đầu vào (ví dụ: học sinh được nối thành học_sinh), mô hình có khả năng nắm bắt trực tiếp các đặc trưng ngữ nghĩa ở cấp độ từ vựng trong tiếng Việt.
- **mModernBERT** (Warner *et al.*, 2025): Phiên bản đa ngôn ngữ của ModernBERT, đại diện cho kiến trúc đã được tối ưu hóa sâu sắc so với bản gốc của BERT. Mô hình này mở rộng độ dài ngữ cảnh lên tới 8192 token, tích hợp cơ chế Attention tăng tốc phần cứng, và thay thế cơ chế mã hóa vị trí tuyệt đối bằng Rotary Position Embedding (RoPE). Những cải tiến này giúp mô hình bắt giữ vị trí và khoảng cách của từ trong câu tốt hơn, từ đó gia tăng độ nhạy bén với các cấu trúc ngữ pháp lỏng lẻo đặc trưng của ngôn ngữ mạng xã hội.

3.6 Các phương pháp đánh giá

Sau khi đã huấn luyện tinh chỉnh, các mô hình cần được đánh giá dựa trên các tiêu chí khách quan nhằm đưa ra góc nhìn về khả năng tổng quát hóa, đồng thời khi đánh giá thực nghiệm cũng sẽ làm giảm các rủi ro khi triển khai mô hình trong thực tế.

Dựa trên các độ đo được trình bày trong các nghiên cứu (Demszky *et al.*, 2020; Hung *et al.*, 2026), mô hình phải được đánh giá trên các tiêu chí trong bảng tổng hợp các độ đo đánh giá hiệu năng mô hình (Bảng 3.3).

Bảng 3.3: Tổng hợp các độ đo đánh giá hiệu năng mô hình.

Độ đo	Ý nghĩa	Công thức
F1-Macro	Trung bình cộng của các chỉ số F1-Score tính riêng biệt cho từng lớp, không phụ thuộc vào số lượng mẫu của lớp đó.	$F1_c = 2 \times \frac{\text{Precision}_c \times \text{Recall}_c}{\text{Precision}_c + \text{Recall}_c}$ $F1_{\text{macro}} = \frac{1}{N} \sum_{i=1}^N F1_{c_i}$
Balanced Accuracy (Độ chính xác cân bằng)	Được thiết kế đặc biệt cho tập dữ liệu mất cân bằng, tính toán trung bình dựa trên độ nhạy (Recall) của từng lớp.	$\text{Balanced Acc} = \frac{1}{N} \sum_{i=1}^N \text{Recall}_{c_i}$
Overall Accuracy (Độ chính xác tổng thể)	Độ chính xác truyền thống, thể hiện tỷ lệ các mẫu được dự đoán đúng trên toàn bộ tập dữ liệu.	$\text{Accuracy} = \frac{T}{N}$ với A là tổng số mẫu dự đoán đúng, N là tổng số mẫu.

Ngoài ra, vì mục tiêu đề án là nghiên cứu xây dựng một khung phương pháp, cho nên ngoài các độ đo định lượng đánh giá các mô hình riêng lẻ, cần phải đánh giá định tính mức độ hành vi trong quá trình học của các mô hình. Nhằm đưa ra góc nhìn khách quan về tính ổn định, tốc độ hội tụ, và mức độ hiệu quả của hàm mất mát hỗn hợp (Mixture Loss) trong việc điều hướng sự chú ý của mô hình vào các nhãn thiểu số; từ đó khẳng định tính đúng đắn, độ tin cậy và khả năng mở rộng của khung phương pháp đề xuất trên nhiều kiến trúc Transformer khác nhau.

CHƯƠNG 4: THỰC NGHIỆM VÀ ĐÁNH GIÁ KẾT QUẢ NGHIÊN CỨU

4.1 Quy trình thực nghiệm

Toàn bộ quy trình triển khai và đánh giá thực nghiệm tất cả các khâu trong khung phương pháp (framework) đều được lập trình bằng ngôn ngữ Python, kết hợp cùng framework học sâu PyTorch và thư viện mã nguồn mở Transformers (Hugging Face).

Về môi trường phần cứng, quá trình huấn luyện và kiểm thử các mô hình (**mBERT**, **PhoBERT** và **mModernBERT**) được thực hiện trên hệ thống máy chủ hiệu năng cao. Hệ thống này được trang bị vi xử lý CPU Intel Xeon® E5-2686 v4 (72 cores), dung lượng bộ nhớ trong (RAM) lên đến 258 GB, cùng bộ xử lý đồ họa (GPU) NVIDIA GeForce RTX 3090 sở hữu 24GB VRAM (năng lực tính toán đạt 35.3 TFLOPS), đảm bảo khả năng xử lý song song khối lượng dữ liệu lớn.

Đối với khâu chuẩn bị dữ liệu, tập ngữ liệu sau khi trải qua quá trình gán nhãn và giảm mẫu đa số (Undersampling) được phân chia ngẫu nhiên thành ba tập con độc lập: tập huấn luyện (Training set), tập kiểm định (Validation set) và tập kiểm thử (Test set) với tỷ lệ phân bổ tương ứng là 90:5:5.

Về quá trình huấn luyện, cấu hình của ba mô hình được thiết lập chi tiết dựa trên các siêu tham số trình bày tại Bảng 4.1. Nhằm tối ưu hóa thời gian tính toán và ngăn chặn hiện tượng quá khớp (overfitting), kỹ thuật dừng sớm (Early Stopping) được tích hợp vào quy trình. Cụ thể, tiến trình huấn luyện sẽ tự động chấm dứt nếu độ đo hiệu năng trên tập kiểm định không ghi nhận sự cải thiện nào sau hai chu kỳ (epochs) liên tiếp.


Bảng 4.1: Cấu hình siêu tham số chi tiết cho từng mô hình thực nghiệm.

Siêu tham số	mBERT	PhoBERT	mModernBERT
Số lượng nhãn phân loại ($n_classes$)	28	28	28
Độ dài chuỗi tối đa (max_len)	512	256	512
Hệ số học ($learning\ rate$)	2.0×10^{-5}	2.0×10^{-5}	1.0×10^{-5}
Số vòng huấn luyện ($epochs$)	12	12	12
Kích thước lô ($batch_size$)	32	32	32
Tích lũy gradient ($accumu-late_steps$)	2	2	2
Kích thước lô hiệu dụng ($ef-fective\ batch$)	64	64	64
Tỷ lệ Dropout	0.1	0.1	0.1
Độ chính xác hỗn hợp ($F16$)	Có	Có	Có
Tham số β (CB-Loss)	0.999	0.999	0.999
Số lượng khoảng ($GHM\ bins$)	10	10	10


4.2 Kết quả thực nghiệm

4.2.1 Kết quả quá trình thu thập, xây dựng, tiền xử lý và gán nhãn dữ liệu

Thông qua các biểu đồ phân phối tập dữ liệu sau quá trình thu thập và xây dựng, tiền xử lý (Hình 4.1 và Hình 4.2) đều có thể thấy được tập ngữ liệu mang đặc tính mất cân bằng sâu sắc mang tính tự nhiên (Long-tail distribution). Các chủ đề mang tính thời sự hoặc giải trí cao (như news, music) thu hút lượng tương tác áp đảo, trong khi các danh mục khác lại vô cùng hạn chế. Sự phân bố không cân bằng này chính là minh chứng cho thấy nếu sử dụng phương pháp luận truyền thống, mô hình sẽ hoàn toàn bị thiên kiến (bias) theo các chủ đề phổ biến. Do đó, việc framework tích hợp **cơ chế gán nhãn bán tự động** (kết hợp luật từ vựng và sinh dữ liệu nhân tạo) cùng **hàm mất mát hỗn hợp (Mixture Loss)** là một bước đi mang tính chiến lược và bắt buộc.




Hình 4.1: Phân phối dữ liệu số lượng bình luận sau quá trình thu thập và tiền xử lý theo các danh mục.



Hình 4.2: Phân phối dữ liệu số lượng video sau quá trình thu thập và tiền xử lý theo các danh mục.

Biểu đồ violin (Hình 4.3) chỉ ra rằng tuyệt đại đa số bình luận của người dùng mạng xã hội Việt Nam thường có độ dài vô cùng ngắn (tập trung ở ngưỡng dưới 20 từ, kể cả icons). Việc phân loại cảm xúc vi mô (fine-grained emotions) trên các đoạn văn bản thiếu hụt ngữ cảnh trầm trọng là một thách thức cực đại đối với học máy. Tuy nhiên, giới hạn này lại làm nổi bật tính đúng đắn trong việc lựa chọn và thiết kế framework. Nhờ việc tinh chỉnh các **kiến trúc Transformer tiên tiến (như mModernBERT với cơ chế Attention tối ưu)**, framework có đủ độ nhạy bén để trích xuất các dấu hiệu

ngữ nghĩa tinh tế nhất chỉ từ một vài từ khóa, vượt qua rào cản về độ dài văn bản mà các mô hình biểu diễn ngữ nghĩa truyền thống thường thất bại. Ngoài ra, sự xuất hiện của các điểm dị thường (outliers) kéo dài lên tới 250 tokens cho thấy độ nhiễu và tính đa dạng hóa của tập ngữ liệu.




Hình 4.3: Biểu đồ violin phân phối số lượng từ trong từng bình luận.


Kết quả của quá trình gán nhãn bán tự động được thể hiện qua phân phối dữ liệu dựa theo các nhóm cảm xúc (Hình 4.4) bộc lộ rõ rệt cấu trúc phân phối đuôi dài (long-tail distribution) mang tính tự nhiên. Các nhãn thuộc nhóm tích cực áp đảo hoàn toàn các nhãn thuộc nhóm tiêu cực. Đồng thời, việc số lượng nhãn trung tính (neutral) đột biến

lại là một tín hiệu tốt và mang tính bảo chứng. Vì thực tế trên mạng xã hội (YouTube, TikTok, Facebook), 70% - 80% bình luận thực tế là vô thưởng vô phạt, ngắn gọn, hoặc thuần túy trần thuật (ví dụ: "video hay", "chấm", "đã xem", "ông A đi xe màu đỏ").

Đồng thời, bức tranh phân bố cảm xúc cũng cho thấy sự tương đồng với tập dữ liệu GoEmotions đã được kiểm chứng nghiêm ngặt (như Hình 4.5). Sự nhất quán về mặt phân phối này khẳng định rằng sự kết hợp giữa luật từ vựng (rule-based) và mô hình ngôn ngữ (Encoder) trong khung phương pháp đã thành công trong việc chuyển giao tri thức (knowledge transfer) từ chuyên gia con người sang hệ thống máy tính với độ sai số được kiểm soát chặt chẽ.




Hình 4.4: Biểu đồ phân phối dữ liệu theo các nhóm cảm xúc (xanh - tích cực, đỏ - tiêu cực, vàng - nhập nhằng, xám - trung tính) sau khi được gán nhãn.




Hình 4.5: Biểu đồ phân phối dữ liệu theo các cảm xúc vi mô trong tập GoEmotions.

Nguồn: (Demszky *et al.*, 2020)


4.2.2 Kết quả quá trình huấn luyện mô hình



Hình 4.6: Biểu đồ hành vi trong quá trình hiệu chỉnh mô hình mBERT.



Hình 4.7: Quá trình hiệu chỉnh mô hình phoBERT.



Hình 4.8: Quá trình hiệu chỉnh mô hình mModernBERT.

Từ ba biểu đồ quá trình huấn luyện trên tập dữ liệu lớn với gần 3 triệu điểm dữ liệu và trên 28 lớp không cân bằng (imbalance) (Hình 4.6, Hình 4.7 và Hình 4.8) cho thấy hiện tượng phân kỳ sớm của giá trị mất mát kiểm định. Tuy nhiên, nếu ta đi vào phân tích sâu hơn, thì có thể nhận thấy rằng đây hoàn toàn là đặc trưng toán học mong muốn khi kết hợp giữa CB-Loss và GHM Loss nhằm bảo vệ các lớp thiểu số.

Đồng thời, hiệu năng thực tế của mô hình (thể hiện qua F1-Macro và Balanced Accuracy) vẫn không hề suy giảm mà vẫn tăng trưởng ổn định. Đặc biệt, các kết quả cũng cho thấy rằng điểm dừng lý tưởng (Early Stopping) rơi vào khoảng 3-5 epoch đầu tiên.

4.2.3 Kết quả quá trình kiểm thử mô hình

Bảng 4.2: Kết quả đánh giá hiệu năng tổng thể của các mô hình trên tập kiểm thử.

Mô hình	F1-Macro	Overall Accuracy	Balanced Accuracy
mBERT	$82.19 \pm 0.38\%$	$82.93 \pm 0.19\%$	$82.35 \pm 0.44\%$
PhoBERT	$82.99 \pm 0.36\%$	$83.84 \pm 0.18\%$	$82.99 \pm 0.43\%$
mModernBERT	$88.94 \pm 0.34\%$	$91.53 \pm 0.14\%$	$89.80 \pm 0.38\%$

Kết quả từ Bảng 4.2 cho thấy mô hình **mModernBERT** đạt hiệu năng cao nhất trên toàn bộ các thang đo, bỏ xa hai mô hình còn lại. Với chỉ số F1-Macro đạt 88.94% và độ chính xác tổng thể (Overall Accuracy) lên tới 91.53%, mModernBERT chứng minh khả năng biểu diễn ngôn ngữ vượt trội. Sự chênh lệch này có thể được lý giải bởi các cải tiến kiến trúc cốt lõi của ModernBERT, bao gồm cơ chế mã hóa vị trí tương đối RoPE (Rotary Position Embedding) và khả năng xử lý ngữ cảnh dài. Những cải tiến này giúp mô hình nắm bắt tốt hơn cấu trúc ngữ pháp lỏng lẻo và các phụ tố cảm xúc phức tạp đặc trưng của ngôn ngữ mạng xã hội.

Khi đối chiếu giữa mBERT và PhoBERT, có thể thấy PhoBERT mang lại kết quả nhỉnh hơn ở cả ba độ đo (F1-Macro đạt 82.99% so với 82.19% của mBERT). Mặc dù có cùng chung nền tảng kiến trúc Encoder cơ sở, PhoBERT được hưởng lợi lớn từ việc tiền huấn luyện (pre-training) hoàn toàn trên ngữ liệu tiếng Việt khổng lồ, kết hợp cùng cơ chế phân đoạn từ (word segmentation).

Một điểm sáng cực kỳ quan trọng trong Bảng 4.2 là sự đồng đều giữa các độ đo **Overall Accuracy** và **F1-Macro / Balanced Accuracy**. Thông thường, trên một tập dữ liệu phân phối đuôi dài, một mô hình kém sẽ có Overall Accuracy rất cao (do đoán bừa nhãn đa số) nhưng F1-Macro lại sụt giảm nghiêm trọng. Tuy nhiên, ở đây chỉ số F1-Macro và Balanced Accuracy của cả ba mô hình đều duy trì ở mức $> 82\%$ (riêng mModernBERT tiệm cận 90%). Kết quả này là bằng chứng mạnh mẽ nhất cho thấy việc kết hợp kỹ thuật giảm mẫu (Undersampling) và hàm điều chuẩn **Mixture Loss (CB-Loss + GHM-Loss)** đã phát huy tác dụng triệt để. Mô hình không bị rơi vào hiện tượng quá khớp với nhãn đa số mà thực sự học được cách phân loại các nhãn cảm xúc thiểu số một cách công bằng.

Độ lệch chuẩn (standard deviation - các giá trị $\pm$) thu được từ quá trình đánh giá chéo trên các thang đo đều duy trì ở mức rất thấp, dao động trong khoảng từ 0.14% đến 0.44%. Phương sai nhỏ này minh chứng cho tính ổn định (robustness) của hệ thống trong suốt quá trình học. Các mô hình đã hội tụ tốt, không bị nhạy cảm (sensitive)

với các thay đổi ngẫu nhiên của các lô dữ liệu (batch) và có khả năng tổng quát hóa (generalization) cao khi đối mặt với dữ liệu chưa từng thấy trong tập kiểm thử.

CHƯƠNG 5: KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

5.1 Kết luận chung

Nghiên cứu đã tiến hành xây dựng và thực nghiệm thành công một khung phương pháp (framework) toàn diện, khép kín từ khâu thu thập, tiền xử lý, gán nhãn cho đến khâu tinh chỉnh mô hình nhằm giải quyết bài toán phân loại cảm xúc vi mô trên ngữ liệu mạng xã hội tiếng Việt. Giá trị cốt lõi của khung phương pháp nằm ở khả năng giải quyết triệt để các thách thức đặc thù của dữ liệu thực tiễn: văn bản thiếu hụt ngữ cảnh, độ nhiễu cao và sự mất cân bằng phân phối nghiêm trọng. Việc thiết lập một quy trình chuẩn hóa không chỉ giúp tối ưu hóa nguồn lực tính toán mà còn cung cấp một nền tảng linh hoạt, có khả năng mở rộng cao cho các bài toán phân tích ngữ nghĩa phức tạp. Từ các cơ sở lý thuyết và minh chứng thực nghiệm định lượng, nghiên cứu rút ra những kết luận trọng tâm sau.

Thứ nhất, về tính thực tiễn của quy trình gán nhãn bán tự động: Việc ứng dụng kết hợp giữa tập luật từ vựng (rule-based) và các Mô hình Ngôn ngữ Lớn (LLMs) dựa trên tập hạt giống (seed data) đã minh chứng được hiệu quả vượt trội. Khung phương pháp này đã giải quyết thành công nút thắt về thời gian và chi phí so với phương pháp gán nhãn chuyên gia truyền thống trên các tập dữ liệu có quy mô lớn. Đặc biệt, phân phối nhãn thu được phản ánh trung thực cấu trúc đuôi dài (long-tail distribution) tự nhiên của ngôn ngữ mạng xã hội, đảm bảo tính khắt khe và hạn chế tối đa hiện tượng gán nhãn sai (false-positives) cho các nhóm cảm xúc thiểu số.

Thứ hai, về năng lực mô hình và kỹ thuật xử lý mất cân bằng dữ liệu: Kết quả thực nghiệm đã khẳng định sự ưu việt tuyệt đối của kiến trúc **mModernBERT** với các cải tiến về cơ chế Attention và mở rộng ngữ cảnh, đạt chỉ số F1-Macro vượt ngưỡng 88%. Thành tựu này có sự đóng góp mang tính quyết định từ chiến lược xử lý dữ liệu mất cân bằng: việc áp dụng kỹ thuật giảm mẫu đa số (Undersampling) kết hợp cùng hàm mất mát hỗn hợp **Mixture Loss** (tích hợp CB-Loss và GHM-Loss). Sự

cộng hưởng này đã điều hướng thành công trọng số học tập của mô hình, giúp hệ thống không bị áp đảo bởi các nhãn phổ biến mà vẫn duy trì độ nhạy bén cao đối với các cảm xúc tiêu cực vi mô, hiếm gặp như sợ hãi (fear), hối hận (remorse) hay thương tiếc (grief).

Tóm lại, sự kết hợp đồng bộ giữa quy trình dữ liệu tự động hóa và các kỹ thuật điều chuẩn mô hình chuyên sâu đã chứng minh được tính đúng đắn, độ tin cậy và sự toàn diện của khung phương pháp đề xuất. Nghiên cứu không chỉ đóng góp một giải pháp học máy tối ưu cho bài toán Phân tích Cảm xúc tiếng Việt, mà còn khẳng định tiềm năng ứng dụng mạnh mẽ vào thực tiễn; tạo tiền đề vững chắc để triển khai các hệ thống lắng nghe xã hội (social listening) và giám sát dư luận tự động với độ chính xác cao.

5.2 Hướng phát triển

Mặc dù khung phương pháp (framework) đề xuất đã đạt được những kết quả thực nghiệm khả quan và chứng minh được tính khả thi, nghiên cứu vẫn còn tồn tại một số giới hạn nhất định. Dựa trên các điểm còn tồn đọng này, các hướng nghiên cứu trong tương lai được định hình nhằm tiếp tục hoàn thiện và mở rộng khả năng ứng dụng của hệ thống.

Nghiên cứu hiện tại chỉ tập trung khai thác và phân tích đặc trưng ngữ nghĩa trên dữ liệu văn bản (text-based). Tuy nhiên, trên các nền tảng mạng xã hội, cảm xúc của người dùng thường bị chi phối mạnh mẽ bởi bối cảnh của video, hình ảnh và âm thanh đi kèm. Việc thiếu hụt dữ liệu đa phương thức có thể dẫn đến sai lệch khi phân tích các bình luận mang tính chất mỉa mai (sarcasm), châm biếm, hoặc sử dụng tiếng lóng phụ thuộc vào ngữ cảnh.

Dù quy trình tạo nhãn giả (pseudo-labeling) đã được kiểm soát chặt chẽ, việc phụ thuộc vào kết quả sinh của các Mô hình Ngôn ngữ Lớn (LLMs) vẫn tiềm ẩn rủi ro sai số (noise) đối với các trạng thái cảm xúc ranh giới (borderline emotions).

Các kiến trúc Transformer kích thước lớn như mModernBERT đòi hỏi năng lực

xử lý phần cứng cao, dẫn đến rào cản về độ trễ (latency) khi triển khai hệ thống phân tích theo thời gian thực (real-time streaming) trên quy mô dữ liệu khổng lồ.

Nhằm khắc phục các hạn chế nêu trên, các hướng phát triển tiếp theo của nghiên cứu sẽ tập trung vào những khía cạnh.

Tích hợp các luồng dữ liệu trích xuất từ âm thanh (audio features) và khung hình video (visual features) kết hợp cùng văn bản để tạo ra một biểu diễn không gian ngữ nghĩa toàn diện. Điều này hứa hẹn sẽ giải quyết triệt để bài toán nhận diện cảm xúc mỉa mai và các ngữ cảnh ẩn.

Tích hợp cơ chế Học chủ động (Active Learning) vào khung phương pháp. Hệ thống sẽ tự động trích xuất những mẫu dữ liệu mà mô hình có độ tin cậy dự đoán thấp nhất để gửi cho chuyên gia con người thẩm định, sau đó cập nhật lại vào tập huấn luyện nhằm liên tục tinh chỉnh chất lượng dữ liệu.

Áp dụng các kỹ thuật như lượng tử hóa (Quantization) hoặc chưng cất tri thức (Knowledge Distillation) để thu gọn kiến trúc mModernBERT thành các phiên bản nhẹ hơn, đảm bảo tốc độ suy luận (inference speed) cao nhưng vẫn giữ vững hiệu năng phân lớp, phục vụ trực tiếp cho các hệ thống giám sát mạng xã hội theo thời gian thực.

Thực nghiệm và đối chiếu hiệu năng của hệ thống hiện tại với các phương pháp tiếp cận dựa trên Prompt Engineering (Few-shot/Zero-shot learning) của các mô hình sinh tiên tiến để đánh giá tiềm năng thay thế hoặc kết hợp.

DANH MỤC TÀI LIỆU THAM KHẢO

Tiếng Anh

- Ahmad, Muhammad, Batyrshin, Ildar, and Sidorov, Grigori (2025). “Sentiment analysis using a large language model–based approach to detect opioids mixed with other substances via social media: method development and validation”. In: *JMIR infodemiology* 5, e70525.
- Benveniste, Damien (2024). *The Transformer Architecture (V2)*. URL: <https://newsletter.theaiedge.io/p/the-transformer-architecture-v2> (visited on 03/21/2026).
- Broder, Andrei Z, Charikar, Moses, Frieze, Alan M, and Mitzenmacher, Michael (1998). “Min-wise independent permutations”. In: *Proceedings of the thirtieth annual ACM symposium on Theory of computing*, pp. 327–336.
- Choudhury, S. (2019). *Five of YouTube’s biggest markets in the world are in Asia*. URL: <https://www.cnbc.com/2019/04/24/five-of-youtubes-biggest-markets-in-the-world-are-in-asia.html> (visited on 05/14/2020).
- Cowen, Alan S, Laukka, Petri, Elfenbein, Hillary Anger, Liu, Runjing, and Keltner, Dacher (2019). “The primacy of categories in the recognition of 12 emotions in speech prosody across two cultures”. In: *Nature human behaviour* 3.4, pp. 369–382.
- Cui, Yin, Jia, Menglin, Lin, Tsung-Yi, Song, Yang, and Belongie, Serge (2019). “Class-balanced loss based on effective number of samples”. In: *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 9268–9277.
- Decision Lab (2025). *The connected consumer Q4 2025*. URL: <https://www.decisionlab.co/decision-lab-connected-consumer-q4-2025> (visited on 03/28/2026).
- Demszky, Dorottya, Movshovitz-Attias, Dana, Ko, Jeongwoo, Cowen, Alan, Nemade, Gaurav, and Ravi, Sujith (2020). “GoEmotions: A dataset of fine-grained emo-

- tions”. In: *Proceedings of the 58th annual meeting of the association for computational linguistics*, pp. 4040–4054.
- Devlin, Jacob, Chang, Ming-Wei, Lee, Kenton, and Toutanova, Kristina (2019). “Bert: Pre-training of deep bidirectional transformers for language understanding”. In: *Proceedings of the 2019 conference of the North American chapter of the association for computational linguistics: human language technologies, volume 1 (long and short papers)*, pp. 4171–4186.
- Ding, Wanfeng, Bhuiyan, Hanif, and Hossain, Md Khalid (2026). “SCOPE: A Transformer-based framework for analyzing sentiment of Chinese public toward delayed retirement”. In: *IEEE Access*.
- Ducange, Pietro, Fazzolari, Michela, Petrocchi, Marinella, and Vecchio, Massimo (2019). “An effective decision support system for social media listening based on cross-source sentiment analysis models”. In: *Engineering Applications of Artificial Intelligence* 78, pp. 71–85.
- Ekman, Paul (1992). “Are there basic emotions?” In: 99.3, pp. 550–553.
- El Azzouzy, Oussama, Chanyour, Tarik, and Andaloussi, Said Jai (2025). “Transformer-based models for sentiment analysis of YouTube video comments”. In: *Scientific African*, e02836.
- Ethnologue (2026). *Ethnologue 200: The 200 largest languages in the world*. URL: <https://www.ethnologue.com/insights/ethnologue200/> (visited on 03/28/2026).
- Gan, Chengguang, Zhang, Qinghao, and Mori, Tatsunori (2023). “Usa: Universal sentiment analysis model & construction of japanese sentiment text classification and part of speech dataset”. In: *arXiv preprint arXiv:2309.03787*.
- Guo, Zhenhua, Jia, Qi, Fan, Baoyu, Wang, Di, Xu, Cong, Wang, Yanwei, Zhao, Yaqian, and Li, Rengang (2024). “MVIndEmo: a dataset for micro video public-induced emotion prediction on social media”. In: *Multimedia Systems* 30.1, p. 58.

- Hung, Tran Quang, Nam, Pham Tien, Luu, Son, and Van Nguyen, Kiet (2026). “Vi-GoEmotions: A Benchmark Dataset For Fine-grained Emotion Detection on Vietnamese Texts”. In: *Proceedings of the 19th Conference of the European Chapter of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 2805–2831.
- Iacoboni, Marco (2009). “Imitation, empathy, and mirror neurons”. In: *Annual review of psychology* 60.1, pp. 653–670.
- Kemp, Simon (2026). *Digital 2026: Vietnam*. DataReportal. URL: <https://datareportal.com/reports/digital-2026-vietnam> (visited on 03/28/2026).
- Le, Anh Quoc, Le, My Trinh, and Ngo, Tan Vu Khanh (2025). “A Hybrid Deep Learning Approach for Spam Comment Detection on Vietnamese Healthcare YouTube Channels”. In: *International Conference on Information and Communication Technology for Intelligent Systems*. Springer, pp. 153–163.
- Lê, Si Lắc (2021). “Nghiên cứu bài toán phân tích cảm xúc của người dùng”. Luận văn/Khóa luận. Thành phố Hồ Chí Minh, Việt Nam: Trường Đại học Công nghệ Thông tin, Đại học Quốc gia Thành phố Hồ Chí Minh.
- LeDoux, Joseph E (2013). “Emotion circuits in the brain”. In: *Fear and anxiety*, pp. 259–288.
- Lee, Lung-Hao, Yu, Liang-Chih, Loukashevich, Natalia, Alimova, Ilseyar, Panchenko, Alexander, Lin, Tzu-Mi, Xu, Zhe-Yu, Zhou, Jian-Yu, Zheng, Guangmin, Wang, Jin, *et al.* (2026). “Dimabsa: Building multilingual and multidomain datasets for dimensional aspect-based sentiment analysis”. In: *arXiv preprint arXiv:2601.23022*.
- Li, Buyu, Liu, Yu, and Wang, Xiaogang (2019). “Gradient harmonized single-stage detector”. In: *Proceedings of the AAAI conference on artificial intelligence*. Vol. 33. 01, pp. 8577–8584.
- Liu, Bing (2012). “Sentiment analysis and opinion mining”. In: pp. 12–13.

- Liu, Bing *et al.* (2010). “Sentiment analysis and subjectivity.” In: *Handbook of natural language processing* 2.2010, pp. 627–666.
- Liu, Yinhan, Ott, Myle, Goyal, Naman, Du, Jingfei, Joshi, Mandar, Chen, Danqi, Levy, Omer, Lewis, Mike, Zettlemoyer, Luke, and Stoyanov, Veselin (2019). “Roberta: A robustly optimized bert pretraining approach”. In: *arXiv preprint arXiv:1907.11692*.
- McDougall, William (2015). *An Introduction to Social Psychology*. Original work published 1908. Psychology Press, pp. 122–126.
- McMeekin, Nicola, Wu, Olivia, Germini, Evi, and Briggs, Andrew (2020). “How methodological frameworks are being developed: evidence from a scoping review”. In: *BMC medical research methodology* 20.1, p. 173.
- Mehrabian, Albert *et al.* (1971). *Silent messages*. Vol. 8. 152. Wadsworth Belmont, CA.
- Minh, Ngo Tan, Hung, Ngo Ba, and Vladimir, Valerievich Stuchilin (2024). “Fine-tuned PhoBERT for sentiment analysis of Vietnamese phone reviews”. In: *CTU Journal of Innovation and Sustainable Development* 16.Special issue: ISDS, pp. 52–57.
- Nguyen, Dat Quoc and Nguyen, Anh-Tuan (2020). “PhoBERT: Pre-trained language models for Vietnamese”. In: *Findings of the association for computational linguistics: EMNLP 2020*, pp. 1037–1042.
- Nguyen, Duy X, Hoan, Hoang V, Vu, Ninh A, Nguyen, Loc T, and Phan, Trung T (2025). “Like or Not to Like: An Usecase of Vietnamese Street Food Videos on YouTube”. In: *Proceedings of the 33rd ACM International Conference on Multimedia*, pp. 7093–7102.
- Nguyen, Nam, Phan, Thang, Nguyen, Duc-Vu, and Van Nguyen, Kiet (2023). “ViSoBERT: a pre-trained language model for Vietnamese social media text processing”. In: *Proceedings of the 2023 Conference on Empirical Methods in Natural Language Processing*, pp. 5191–5207.

Quoc Tran, Khanh, Trong Nguyen, An, Hoang, Phu Gia, Luu, Canh Duc, Do, Trong-Hop, and Van Nguyen, Kiet (2023). “Vietnamese hate and offensive detection using PhoBERT-CNN and social media streaming data”. In: *Neural Computing and Applications* 35.1, pp. 573–594.

Radford, Alec, Narasimhan, Karthik, Salimans, Tim, Sutskever, Ilya, *et al.* (2018). “Improving language understanding by generative pre-training”. In.

Ratner, Alexander, Bach, Stephen H, Ehrenberg, Henry, Fries, Jason, Wu, Sen, and Ré, Christopher (2017). “Snorkel: Rapid training data creation with weak supervision”. In: *Proceedings of the VLDB endowment. International conference on very large data bases*. Vol. 11. 3, p. 269.

Ribeiro, Manoel Horta and West, Robert (2021). “Youniverse: Large-scale channel and video metadata from english-speaking youtube”. In: *Proceedings of the International AAAI Conference on Web and Social Media*. Vol. 15, pp. 1016–1024.

Shen, Chuming, Wei, Wei, Wang, Dong, and Wang, Zhonghao (2025). “Zero-Shot Cross-Domain Aspect-Based Sentiment Analysis via Domain-Contextualized Chain-of-Thought Reasoning”. In: *Findings of the Association for Computational Linguistics: EMNLP 2025*, pp. 4558–4573.

Singh, Ritika and Tiwari, Ayushka (2021). “Youtube comments sentiment analysis”. In: *International Journal of Scientific Research in Engineering and Management (IJSREM)* 5.5, pp. 1–11.

Social Blade LLC (2026). *Social Blade - YouTube, Twitch, Twitter, & Instagram Statistics*. Truy cập ngày: 19/03/2026.

Uma Maheswari, G., Krishna Harni, P., Sangeetha, K., and Zenmathy, K. P. (2024). “Sentiment Synthesis: Transforming YouTube Comments into Strategic Insights”.

In: *Department of CSE, Kamaraj College of Engineering and Technology*. Emails: umamaheswaricse@kamarajengg.edu.in, 21ucs017@kamarajengg.edu.in, 21ucs012@kamarajengg.edu.in, 21ucs014@kamarajengg.edu.in.

- Vaswani, Ashish, Shazeer, Noam, Parmar, Niki, Uszkoreit, Jakob, Jones, Llion, Gomez, Aidan N, Kaiser, Łukasz, and Polosukhin, Illia (2017). “Attention is all you need”. In: *Advances in neural information processing systems* 30.
- Wang, Yizhong, Kordi, Yeganeh, Mishra, Swaroop, Liu, Alisa, Smith, Noah A, Khashabi, Daniel, and Hajishirzi, Hannaneh (2023). “Self-instruct: Aligning language models with self-generated instructions”. In: *Proceedings of the 61st annual meeting of the association for computational linguistics (volume 1: long papers)*, pp. 13484–13508.
- Warner, Benjamin, Chaffin, Antoine, Clavié, Benjamin, Weller, Orion, Hallström, Oskar, Taghadouini, Said, Gallagher, Alexis, Biswas, Raja, Ladhak, Faisal, Aarsen, Tom, *et al.* (2025). “Smarter, better, faster, longer: A modern bidirectional encoder for fast, memory efficient, and long context finetuning and inference”. In: *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pp. 2526–2547.
- Watson, David and Tellegen, Auke (1985). “Toward a consensual structure of mood.” In: *Psychological bulletin* 98.2, p. 219.
- Wiebe, Janyce, Wilson, Theresa, and Cardie, Claire (2005). “Annotating expressions of opinions and emotions in language”. In: *Language Resources and Evaluation* 39.2, pp. 165–210.
- Yue, Lin, Chen, Weitong, Li, Xue, Zuo, Wanli, and Yin, Minghao (2019). “A survey of sentiment analysis in social media.” In: *Knowledge & Information Systems* 60.2.
- Zhao, Jianyu and Ji, Zhuoran (2018). “LSICC: A Large Scale Informal Chinese Corpus”. In: *arXiv preprint arXiv:1811.10167*.
- Zhao, Ping (2025). “An Interpretable and Visual Deep Learning Framework for Korean Sentiment Analysis in Multi-Domain Service Scenarios”. In: *International Journal of Information Systems in the Service Sector (IJISSS)* 16.1, pp. 1–17.

ZHAO, Wen-hui, WU, Xiao-ling, LING, Jie, and HOON, Heo (2024). “Multi-domain sentiment analysis of Chinese text based on prompt tuning”. In: *Computer Engineering & Science* 46.1, p. 179.